Visão Computacional: Filtragem, morfologia e segmentação

Dr. Daniel Oliveira
danieltmo3@gmail.com

Processamento de Imagens Coloridas

O que são Imagens Coloridas?

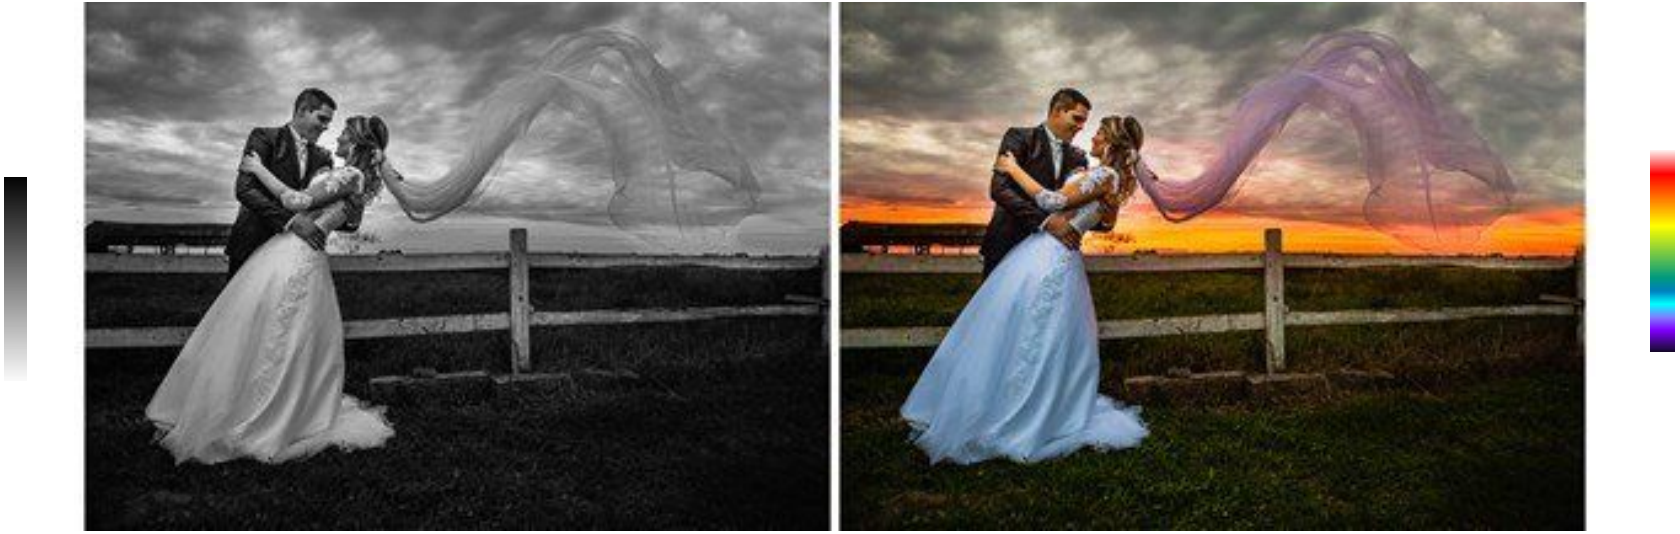

Humanos distinguem milhares de tonalidades de cor e intensidades (enquanto se restringe a dezenas de níveis de cinza)

Fundamentos da cor

As cores que os seres humanos percebem vem da luz refletida em objetos

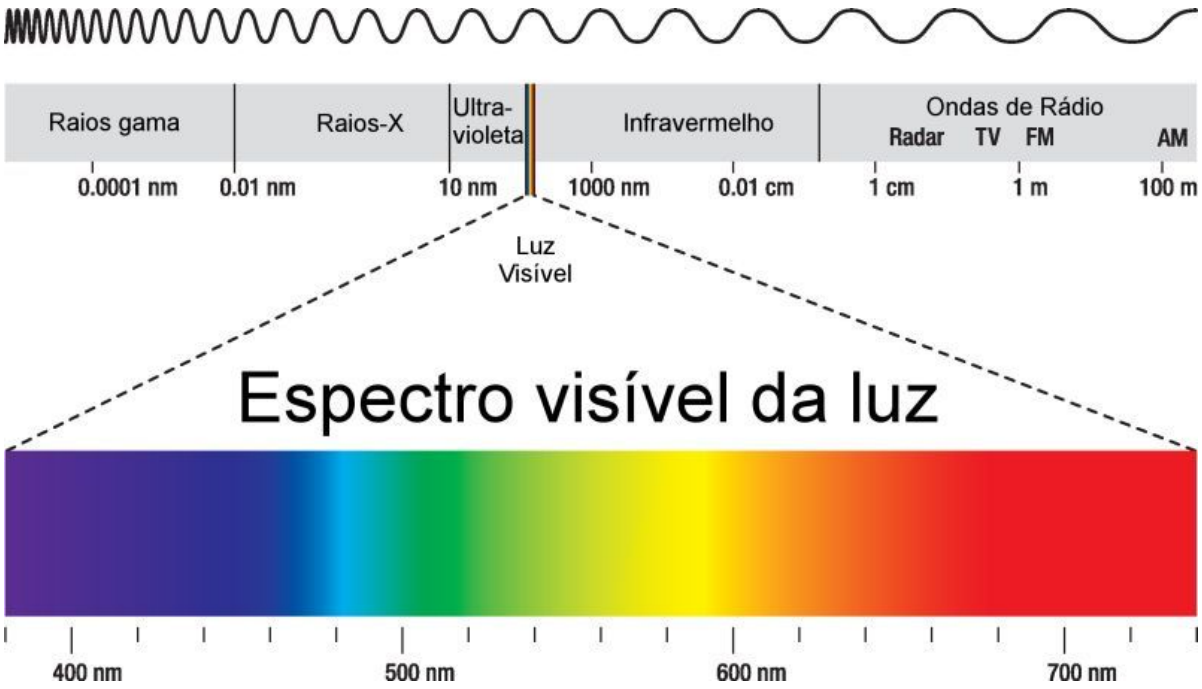

Conceitos

- **Imagem digital:** é representada por uma matriz bidimensional de números que representam a informação da cor em cada ponto (pixel)
- **Pixel:** Menor unidade de uma imagem digital
- **Resolução:** Quantidade de pixels na horizontal x vertical (1920 x 1080)
- **Profundidade:** Número de bits utilizado para representar a cor de cada pixel

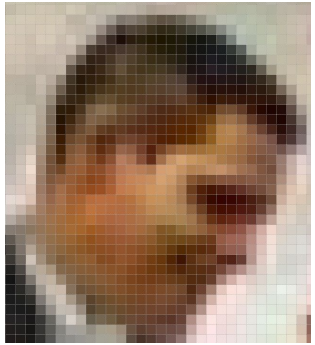

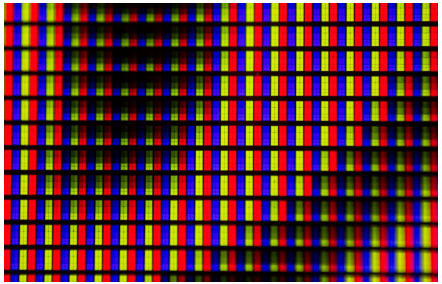

Processamento de Imagens Coloridas

Divide-se em duas grandes áreas

Full-color: Cada pixel possui valores reais de intensidade para cada canal de cor primário

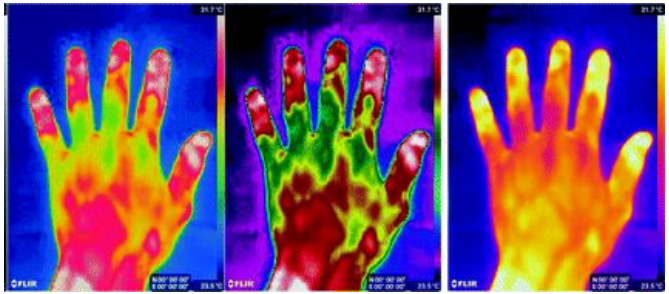

Pseudocolor: Valores de intensidade (geralmente de imagens em escala de cinza) são mapeados para cores a partir de uma tabela de cores

Modelos de Cor

Escala de Cinza: 1 canal (cinza)
RGB (Red, Green, Blue): 3 canais (vermelho, azul, verde). Ex: monitores
CMY/CMYK: 3 canais (ciano, magenta, amarelo). Ex: Impressão
HSI: Representação por matiz, saturação e intensidade. Similar como o humano interpreta cores

Vermelho

Verde

Azul

Modelos de Cor

Processamento de Imagens Coloridas

Diferentes modelos de cor tendem a ter melhores resultados em diferentes processamentos de imagens

Para o RGB, processar cada canal de cor de forma independente pode levar a resultados não satisfatórios, sendo o HSI o modelo mais adequado

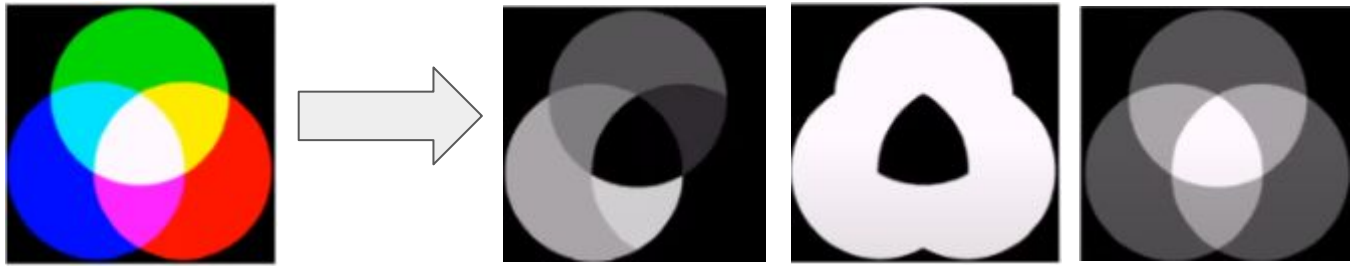

RGB **HSI**

Ajustando intensidade

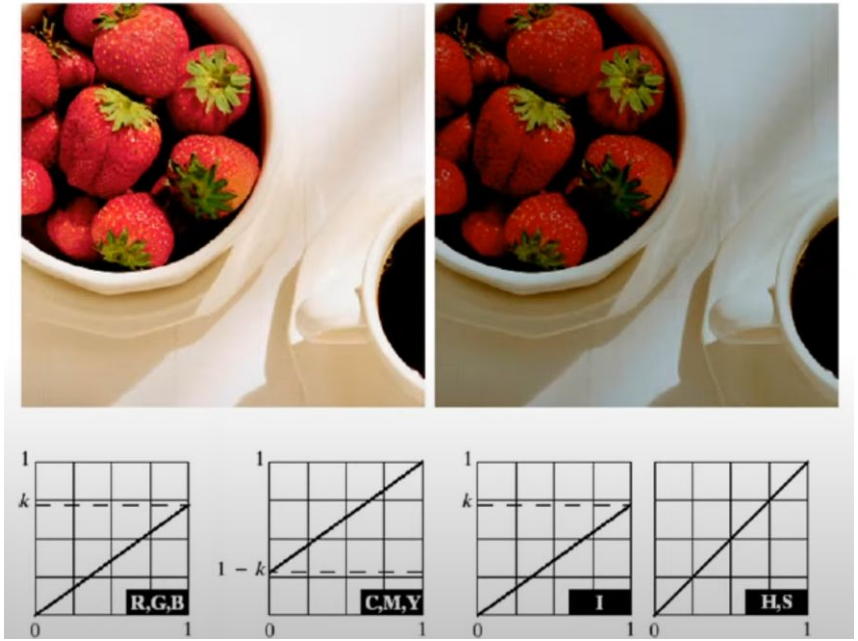

RGB: Multiplica cada cor por k

CMY: Multiplica cada cor por 1-k

HSI: Multiplica apenas a intensidade por k

Convertendo RGB em HSI

1. Intensidade (I)

$$I = \frac{R + G + B}{3}$$

Média aritmética dos valores RGB

Normalizado entre 0 e 1.

Convertendo RGB em HSI

1 Intensidade (I)

$$I = \frac{R + G + B}{3}$$

2 Saturação (S)

$$S = 1 - \frac{3}{R + G + B} \times \min(R, G, B)$$

Mede a pureza da cor

0: tom acinzentado, 1: cor pura

Se (R + G + B) = 0, então S = 0

Convertendo RGB em HSI

1 Intensidade (I)

$$I = \frac{R + G + B}{3}$$

2 Saturação (S)

$$S = 1 - \frac{\ldots}{R + \ldots}$$

3 Matiz (H)

$$\theta = \cos^{-1}\left(\frac{1/2 \times [(R-G)+(R-B)]}{\sqrt{(R-G)^2+(R-B)(G-B)}}\right)$$

Se B ≤ G → H = θ

Se B > G → H = 360° – θ

Definido em graus (0° a 360°)

Representa a 'cor' percebida.

Diferentes Níveis processamento

Nível Baixo : Responsável pela remoção de dados indesejáveis e realce de dados importantes

Nível Médio: Responsável por identificar formas significantes, segmentação

Nível Alto: Responsável pela ligação da imagem com algum banco de conhecimento

Equalização de Histograma (nível baixo)

Melhoria de contraste usada em processamento de imagens. Ela redistribui os níveis de intensidade dos pixels para ocupar de forma mais uniforme toda a faixa de valores possíveis

Faz com que áreas escuras fiquem mais claras e áreas claras fiquem mais definidas, realçando detalhes ocultos

Equalização de Histograma (nível baixo)

O histograma indica a quantidade de vezes que cada pixel apareceu, não levando em consideração a posição do pixel

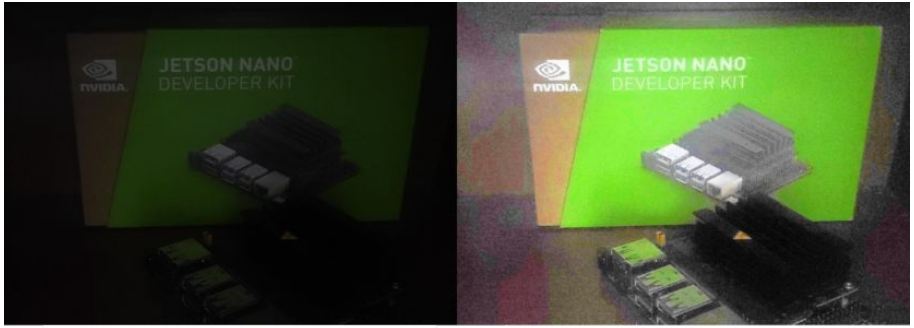

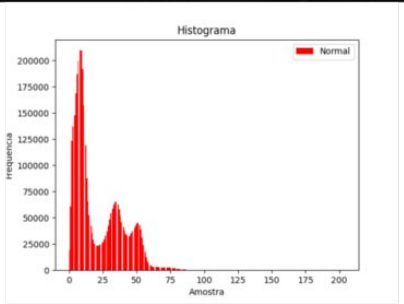

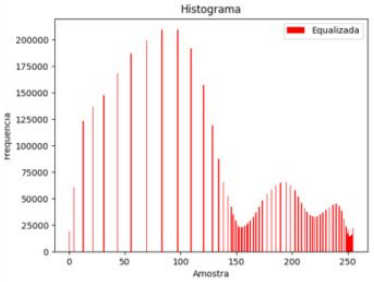

Equalização de Histograma (nível baixo)

Em imagens coloridas, deve-se evitar alterar a coloração de cada canal de forma distinta, o que ocorreria no modelo RGB

A abordagem mais comum é:

1. **Converter** a imagem para um espaço de cor como **HSV/HSI**
2. Aplicar a equalização **apenas no canal de luminância** (V ou I), mantendo os canais de cor intactos
3. **Converter de volta** para RGB

Quantização (nível baixo)

Reduz o número de bits em cada canal (profundidade), por consequência, reduzindo o número de cores

Reduz tamanho da imagem

Filtragem por máscaras (baixo) (convolução em imagens)

Máscaras são **imagens ou matrizes binárias** (ou com valores específicos) aplicadas sobre uma imagem original

Permitem **modificar, isolar ou realçar** certas regiões da imagem.

$$\text{pixel_saida}(x, y) = \sum(\text{vizinhança} \cdot \text{kernel})$$

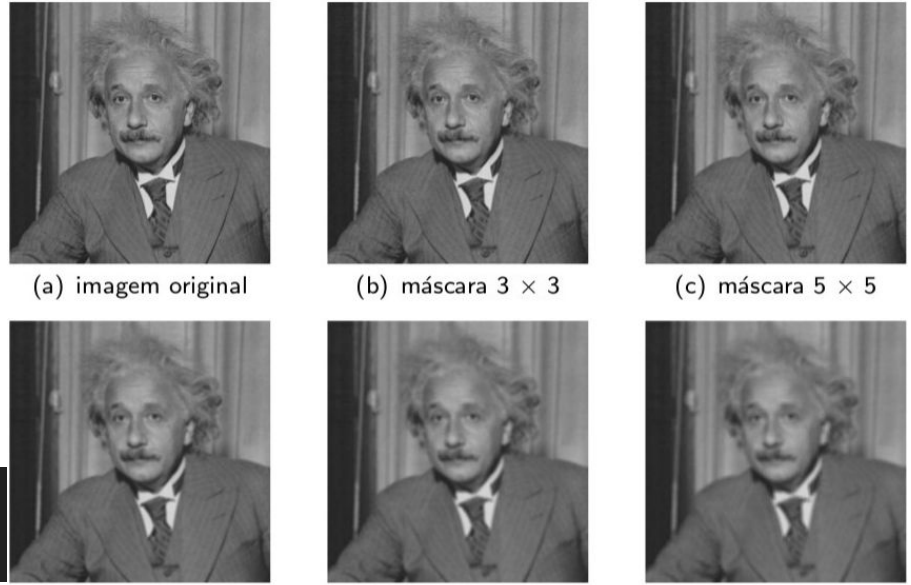

(a) imagem original (b) máscara 3 × 3 (c) máscara 5 × 5

(d) máscara 7 × 7 (e) máscara 9 × 9 (f) máscara 11 × 11

Convolução em imagens 2D

Convolução é o processo de deslizar um filtro (kernel) sobre a imagem e, em cada posição, calcular uma soma ponderada dos pixels vizinhos para gerar o valor do pixel de saída.

$$\text{pixel_saida}(x, y) = \sum(\text{vizinhança} \cdot \text{kernel})$$

Filtragem por máscaras (baixo/médio)

Filtros Passa-baixa: Suavizam os detalhes como ruído e texturas finas e preservam áreas suaves. **Exemplos**: Filtros de média, Gaussiano, mediana.

Processamento de baixo nível (Majoritariamente)

Filtro Passa-Alta: Acentuam os detalhes como bordas e transições abruptas entre regiões. **Exemplos**: Filtro de Sobel, Laplaciano.

Processamento de nível médio (Majoritariamente)

Máscara de Suavização (Passa-baixo)

Uma das máscaras mais simples de suavização é a **máscara média**, que atribui a mesma importância para todos os pixels vizinhos ao redor de um pixel central

1/9 x

1	1	1
1	1	1
1	1	1

A operação consiste em calcular a média dos valores dos pixels vizinhos e substituir o valor central pela média

Máscara de Suavização (Passa-baixo)

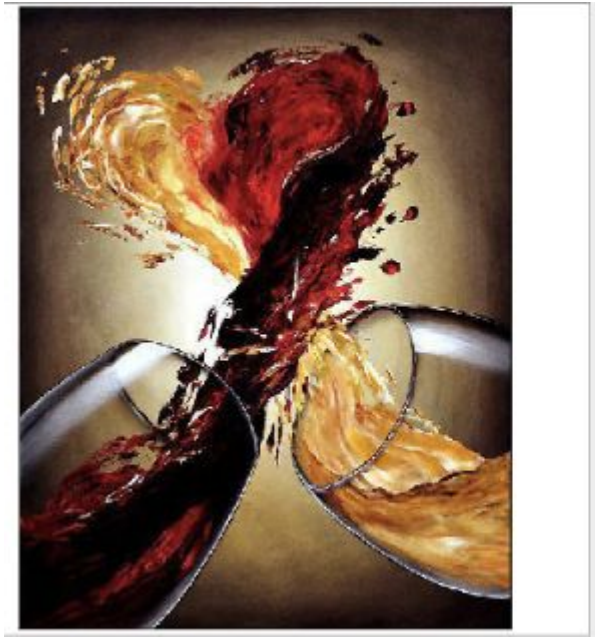

Máscara de Suavização (Passa-baixo)

Outros filtros de suavização são

Filtro Gaussiano: Aplica uma **distribuição gaussiana** para suavizar a imagem, dando maior peso aos pixels próximos ao centro

2	4	5	4	2
4	9	12	9	4
5	12	15	12	5
4	9	12	9	4
2	4	5	4	2

Filtro Mediana: Substitui o valor do pixel central pela **mediana** dos valores dos pixels ao seu redor

223	186	114
204	161	106
219	194	138

106 114 138 161 **186** 194 204 219 223

Filtros Passa-alta

Útil para destacar **contornos e detalhes estruturais**, que são fundamentais em várias aplicações, como **detecção de bordas, pontos, linhas** e **identificação de formas**. Temos como exemplo o **Filtro de Sobel e Laplaciano**

Filtros de Sobel (Passa-alta)

Detecção de bordas que calcula a **derivada aproximada** da intensidade de imagem nas direções horizontal e vertical

Horizontal

-1	0	1
-2	0	2
-1	0	1

Vertical

1	2	1
0	0	0
-1	-2	-1

Filtros de Sobel (Passa-alta)

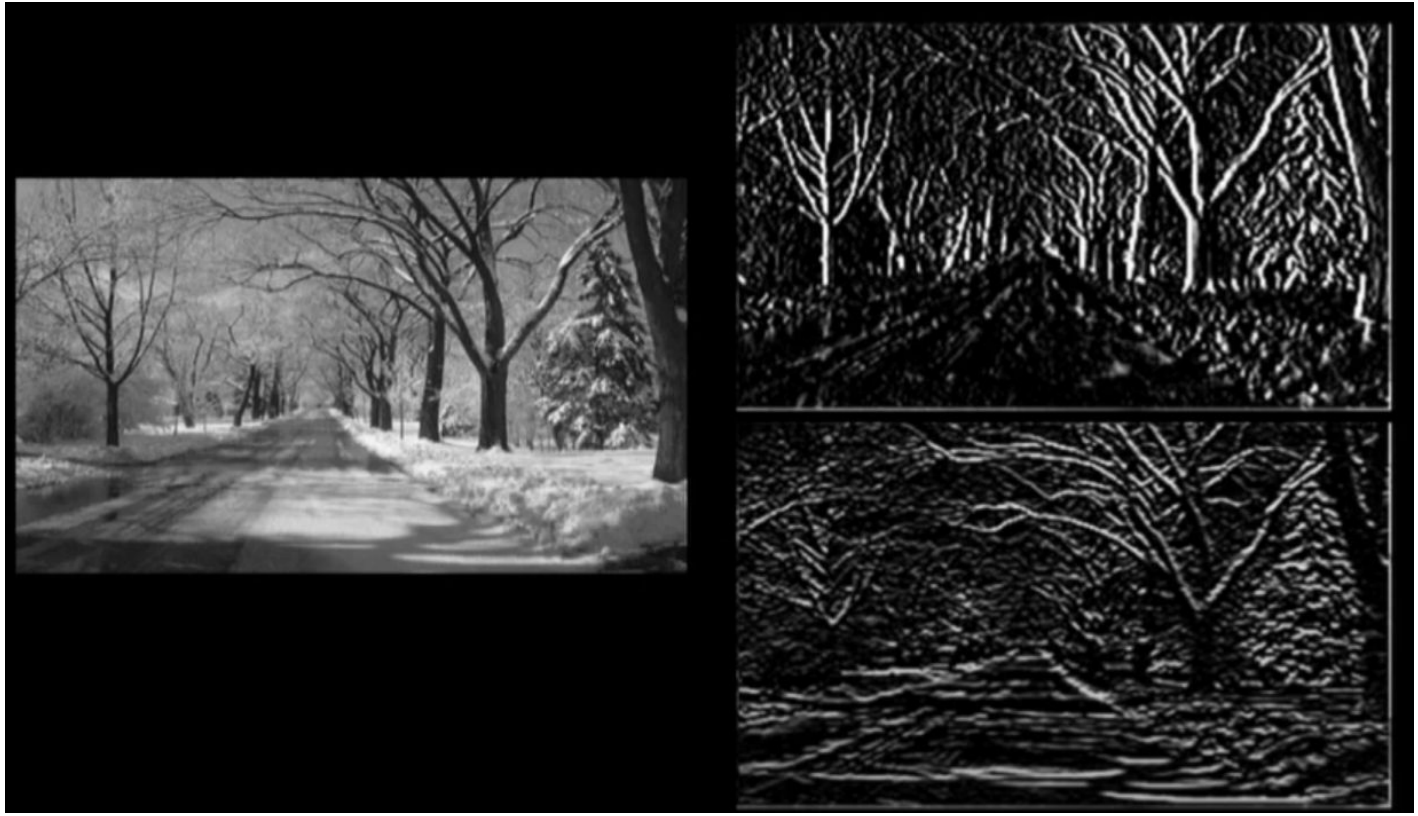

Horizontal

Vertical

Filtros de Laplaciano (Passa-alta)

Calcula a intensidade da imagem **destaca bordas** e transições rápidas, sendo **sensível a mudanças rápidas** na intensidade e gerando uma resposta forte nas bordas (Detecção de pontos)

Remove bordas interiores

-1	-1	-1
-1	8	-1
-1	-1	-1

0	-1	0
-1	4	-1
0	-1	0

Remove bordas exteriores

0	1	0
1	-4	1
0	1	0

1	1	1
1	-8	1
1	1	1

Filtros de Laplaciano (Passa-alta)

Detecção de linhas

Linhas são estruturas alongadas detectadas por **máscaras direcionais** sensíveis à orientação. Cada máscara responde a uma direção específica.

Máscara Horizontal

$$\begin{bmatrix} -1 & -1 & -1 \\ 2 & 2 & 2 \\ -1 & -1 & -1 \end{bmatrix}$$

Realça linhas na direção **horizontal**.

Máscara Vertical

$$\begin{bmatrix} -1 & 2 & -1 \\ -1 & 2 & -1 \\ -1 & 2 & -1 \end{bmatrix}$$

Realça linhas na direção **vertical**.

Processamento Morfológico de Imagens

A palavra morfologia significa o estudo da **forma** e da **estrutura** dos objetos.

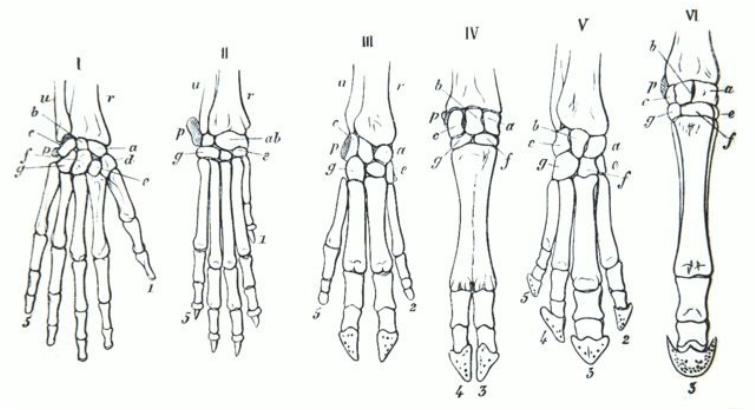

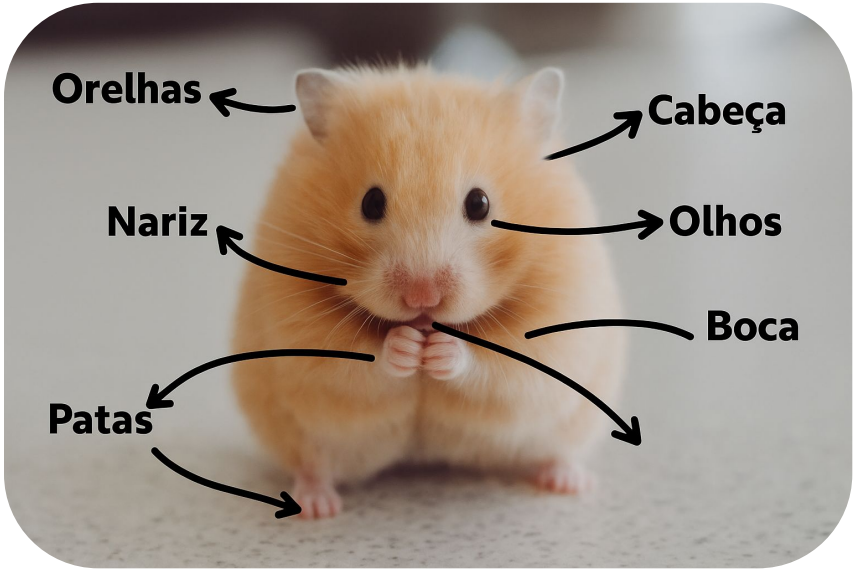

Na computação, usamos um ramo chamado **Morfologia Matemática**

Processamento Morfológico de Imagens

Conjunto de técnicas de processamento de imagens baseadas na **forma** e **estrutura** dos objetos presentes na imagem

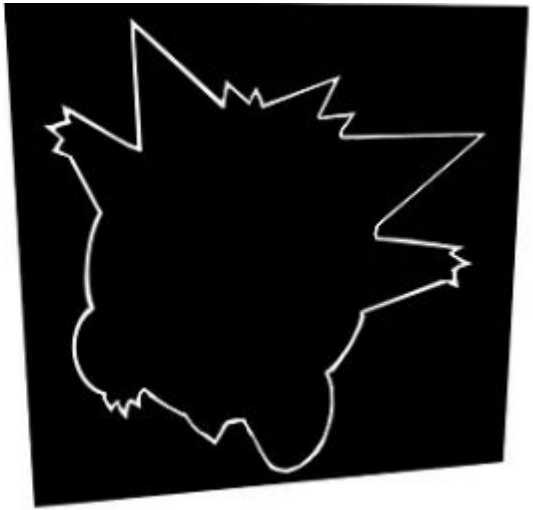

Processamento Morfológico de Imagens

Manipular formas e **estruturas** de objetos em imagens binárias e tons de cinza ressaltando aspectos específicos das formas

- Remover ruídos
- Unir ou separar objetos
- Destacar contornos e regiões
- Realizar operações de segmentação

Conceitos

Imagem Binária: Composta de apenas pixels pretos e brancos

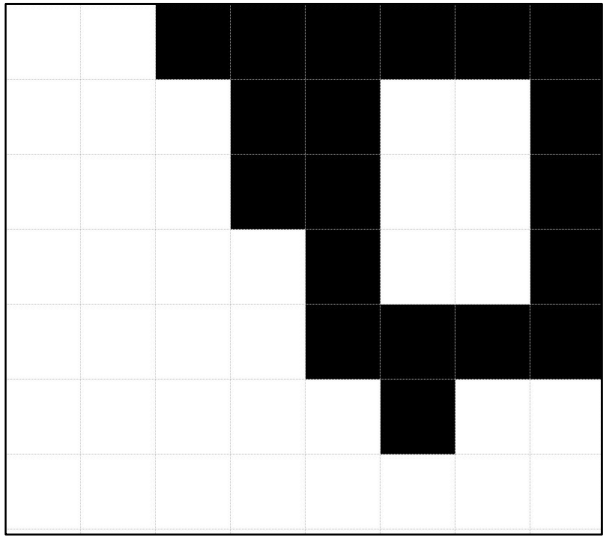

0	0	1	1	1	1	1	1
0	0	0	1	1	0	0	1
0	0	0	1	1	0	0	1
0	0	0	0	1	0	0	1
0	0	0	0	1	1	1	1
0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	0

A= {(2,0), (3,0), (4,0), (5,0), (6,0), (7,0), … ,(5,5)}

Operações Morfológicas

Processamentos de imagens binárias que utilizam um **Elemento Estruturante (EE)** como base para modificar a geometria dos objetos na imagem, considerando a vizinhança dos pixels

Principais operações

- Dilatação
- Erosão
- Abertura
- Fechamento

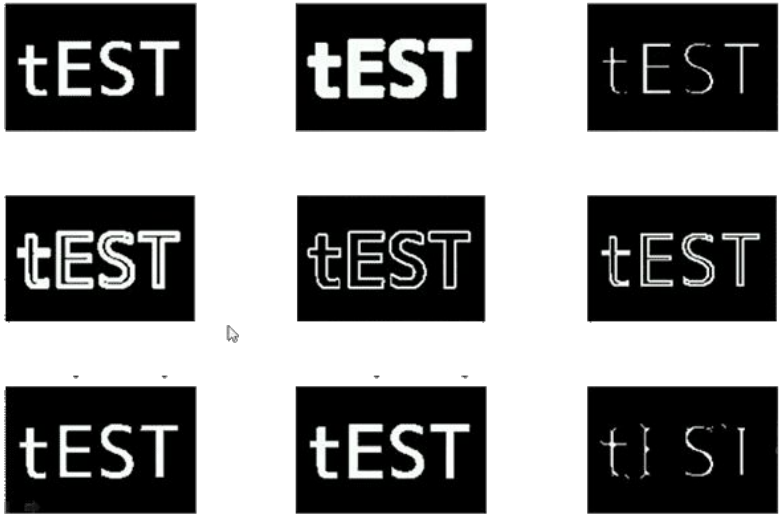

Operações Morfológicas

Elemento Estruturante:

- Pequena matriz com um ponto de origem (0,0)
- A origem será colocada sobre cada pixel pintado da imagem
- Pode ser quadrado, cruz, círculo ou qualquer formato

Dilatação

Adiciona pixels às bordas dos objetos, aumentando seu tamanho

Condição: Se o ponto de origem do elemento estruturante estiver sobre um pixel pintado, então grava o Elemento Estruturante na imagem

```
Para cada pixel (x, y) na imagem:
    Se pixel (x, y) == 1:
        Para cada posição (i, j) no Elemento Estruturante:
            Se EE(i, j) == 1:
                Definir pixel (x+i, y+j) na imagem de saída como 1
```

Dilatação

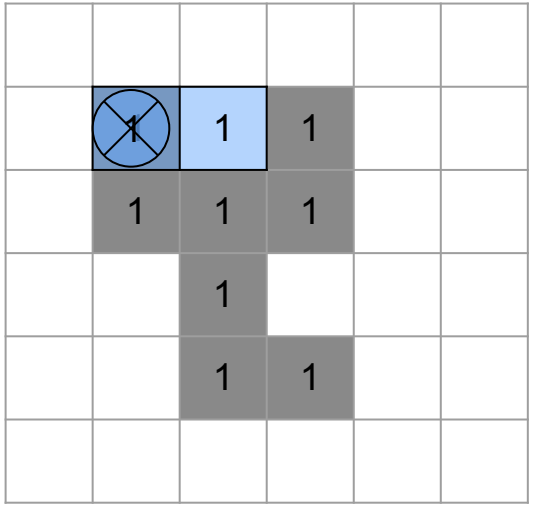

Imagem A

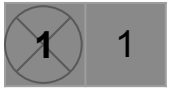

EE

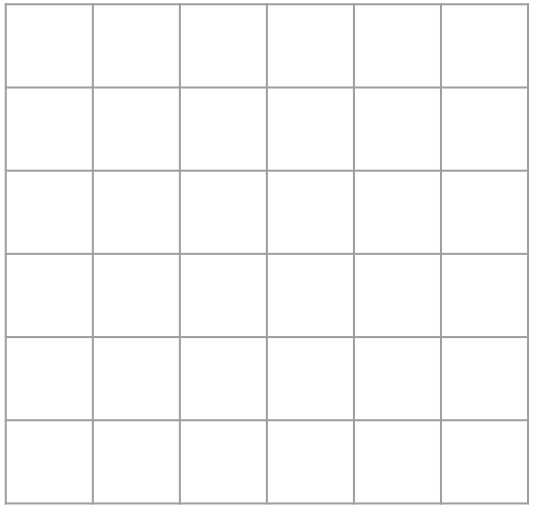

Resultado

Dilatação

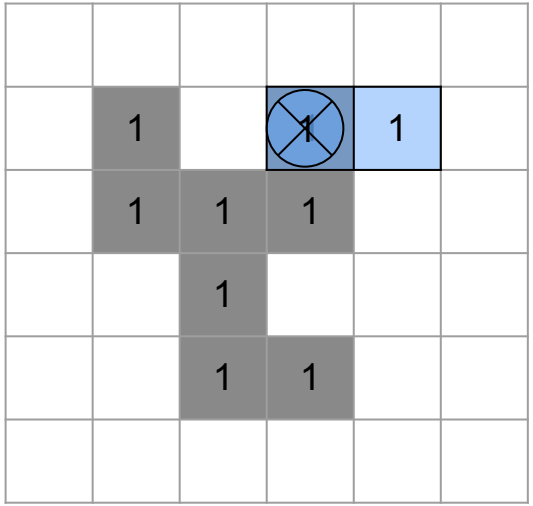

Imagem A

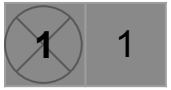

EE

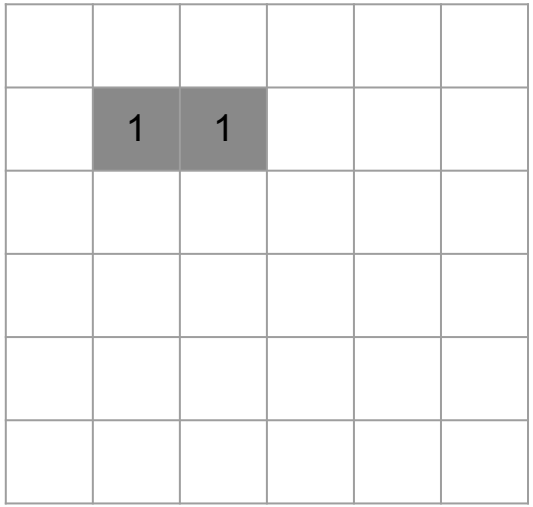

Resultado

Dilatação

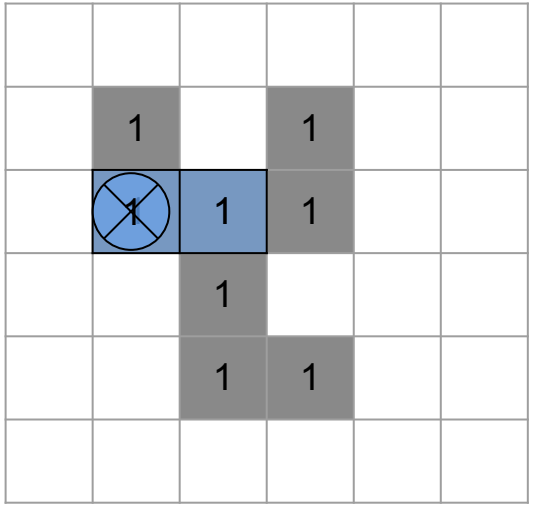

Imagem A

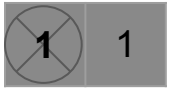

EE

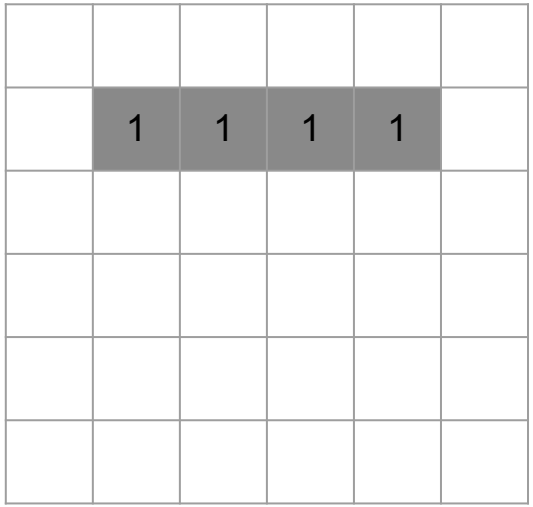

Resultado

Dilatação

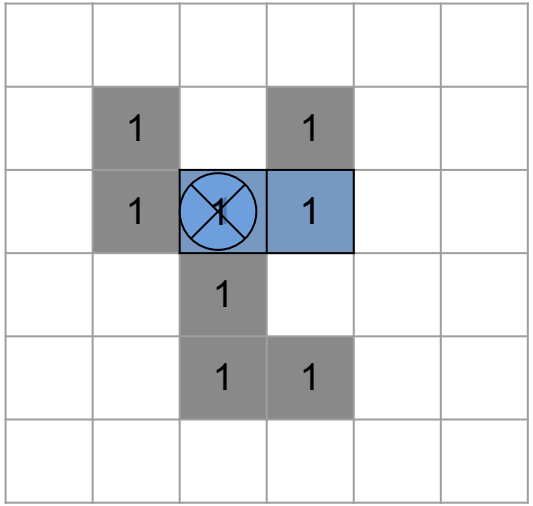

Imagem A

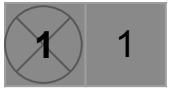

EE

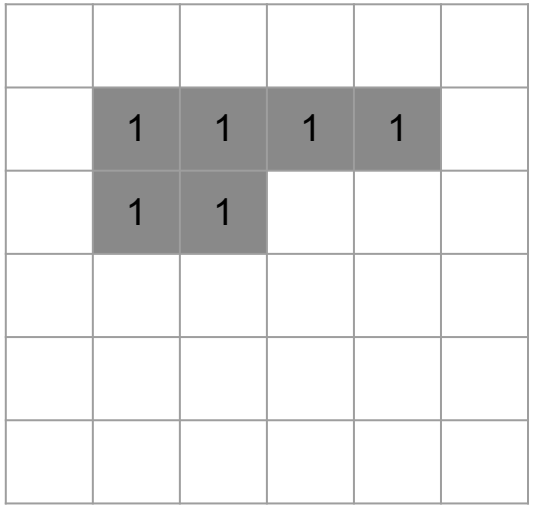

Resultado

Dilatação

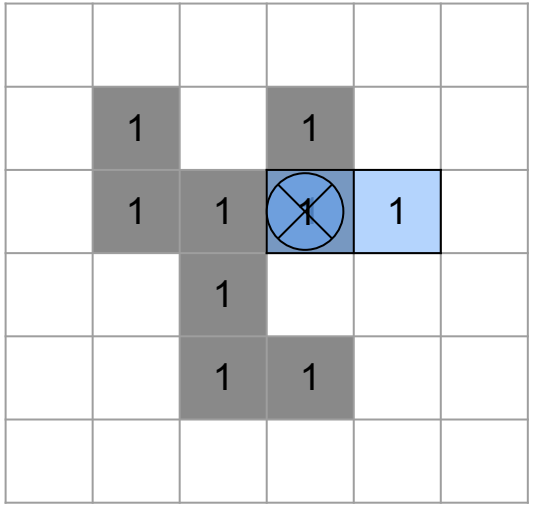

Imagem A

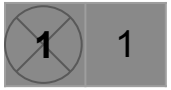

EE

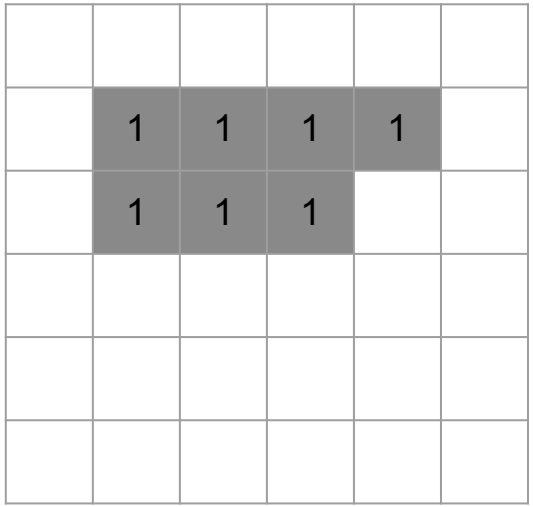

Resultado

Dilatação

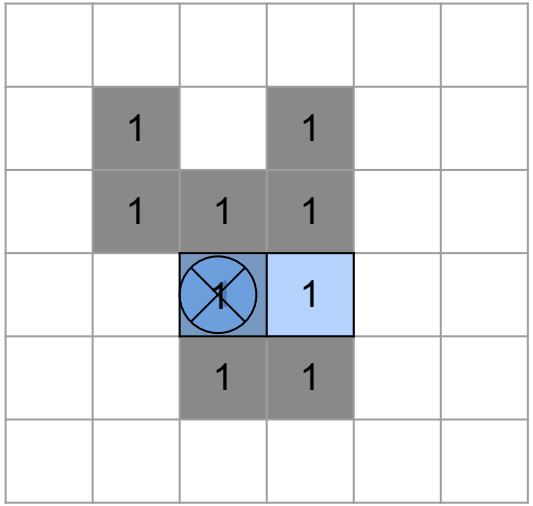

Imagem A

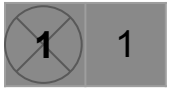

EE

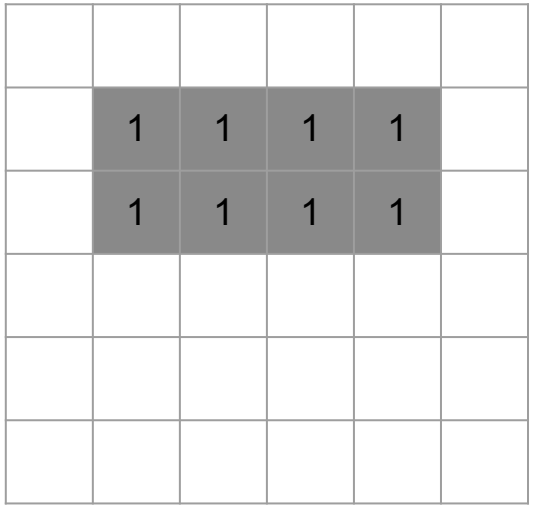

Resultado

Dilatação

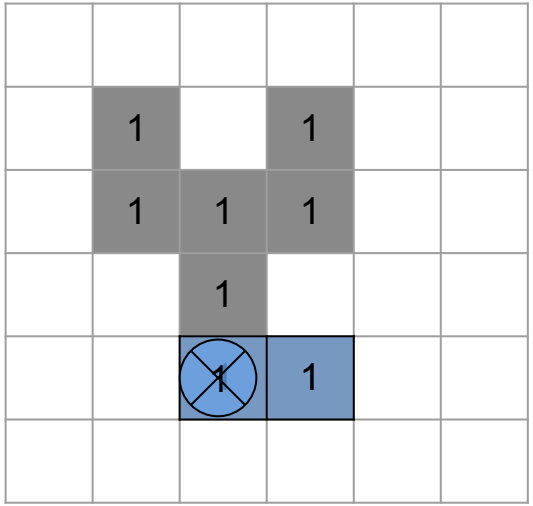

Imagem A

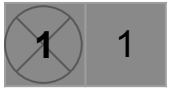

EE

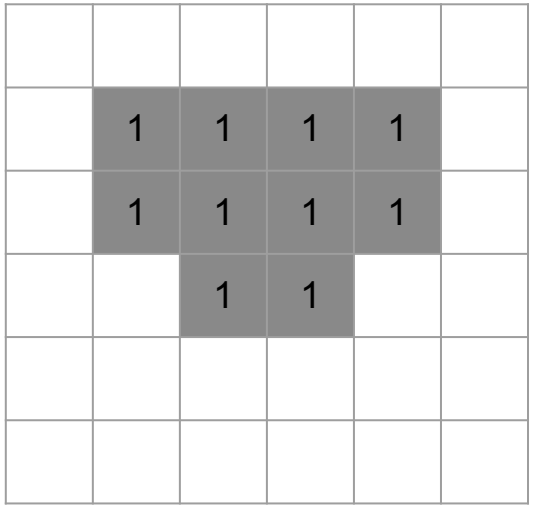

Resultado

Dilatação

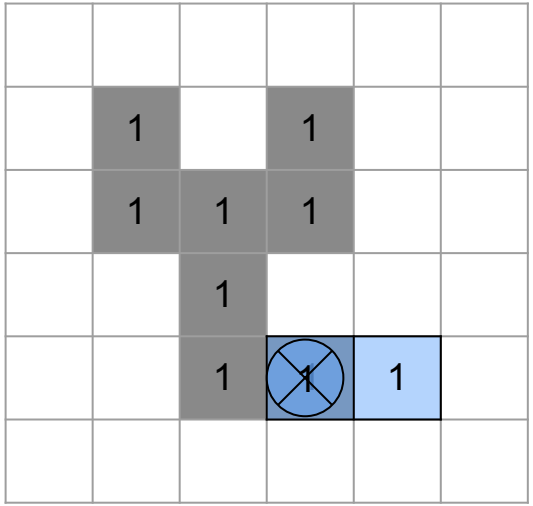

Imagem A

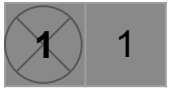

EE

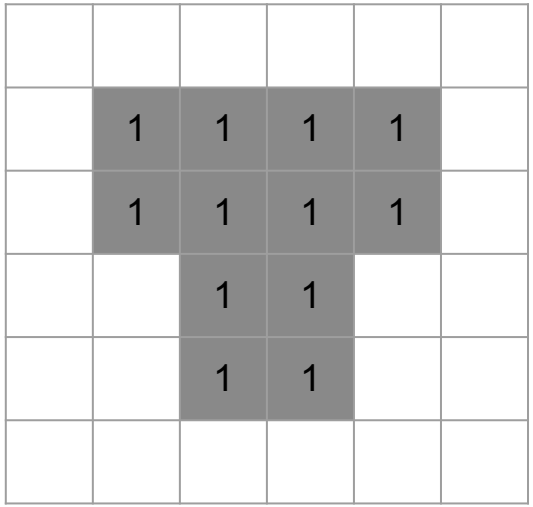

Resultado

Dilatação

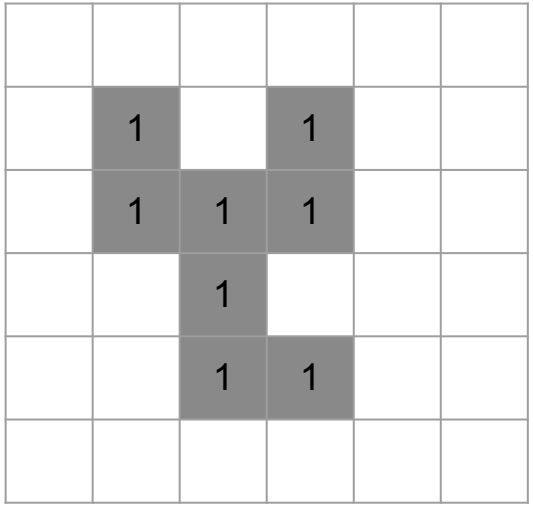

Imagem A

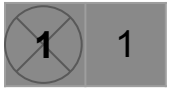

EE

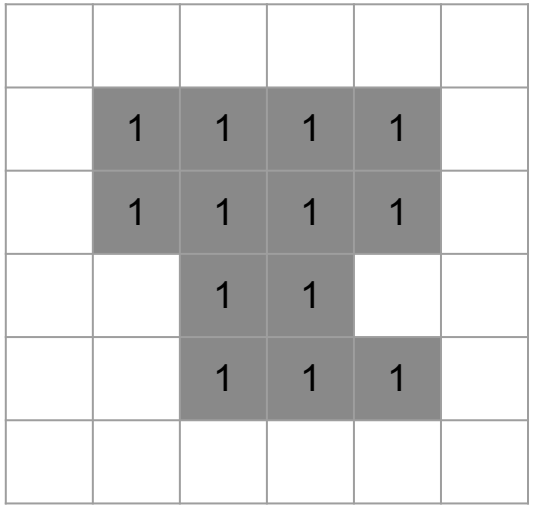

Resultado

Dilatação

Resultado: Objetos se expandem e pequenas lacunas são preenchidas.

Dilatação

Resultado: Objetos se expandem e pequenas lacunas são preenchidas.

Erosão

Remove pixels das bordas dos objetos, diminuindo seu tamanho.

Condição: Se todos os 1's do EE coincidirem com 1's na imagem quando a origem está sobre o pixel pintado, grava o pixel sob o elemento de origem

```
Para cada pixel (x, y) na imagem:
    Definir flag = 1
    Para cada posição (i, j) no EE:
        Se EE(i, j) == 1 e pixel (x+i, y+j) != 1:
            flag = 0
            sair do laço
    Definir pixel (x, y) na imagem de saída como flag
```

Erosão

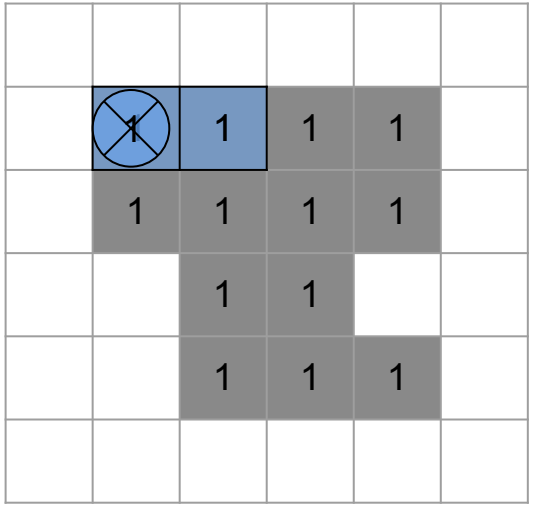

Imagem A

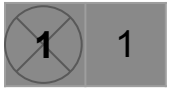

EE

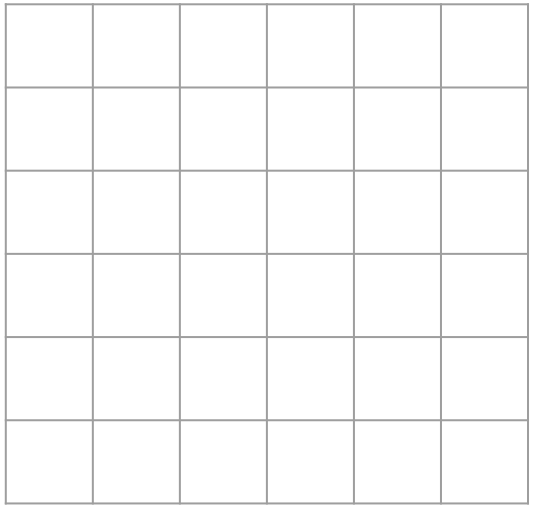

Resultado

Erosão

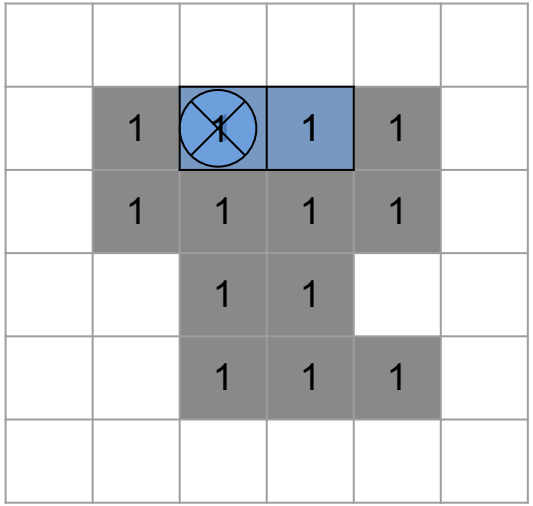

Imagem A

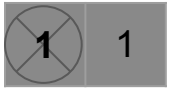

EE

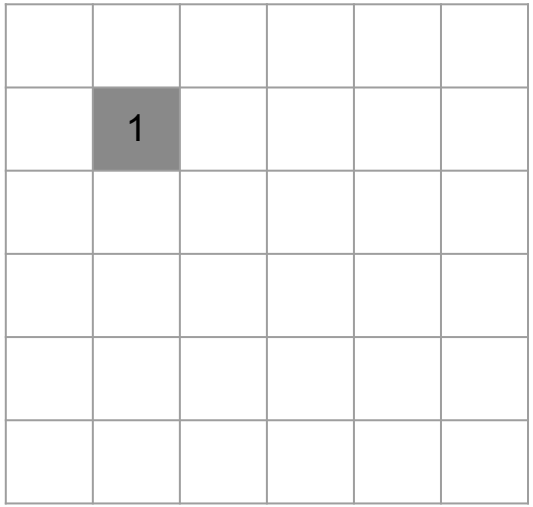

Resultado

Erosão

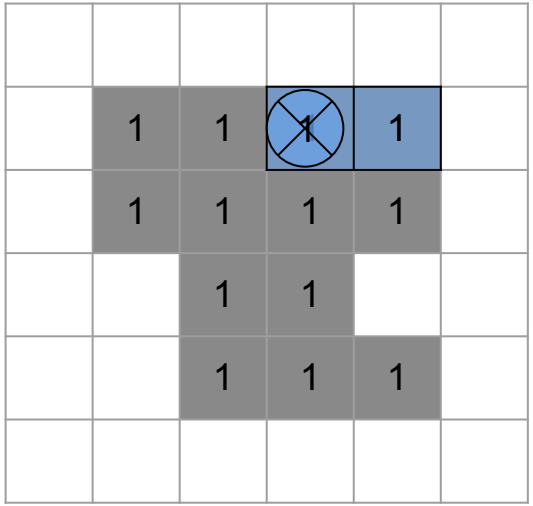

Imagem A

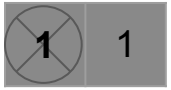

EE

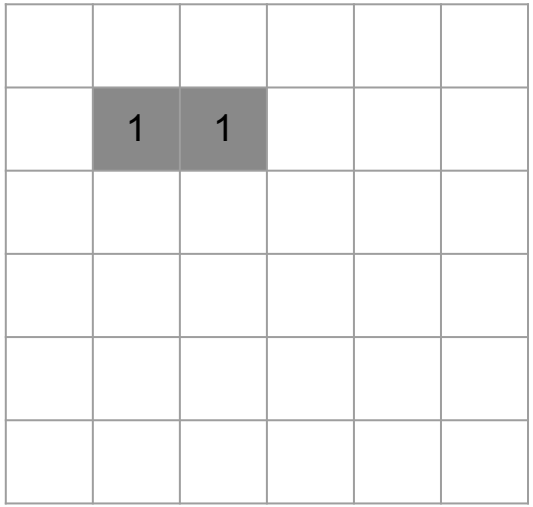

Resultado

Erosão

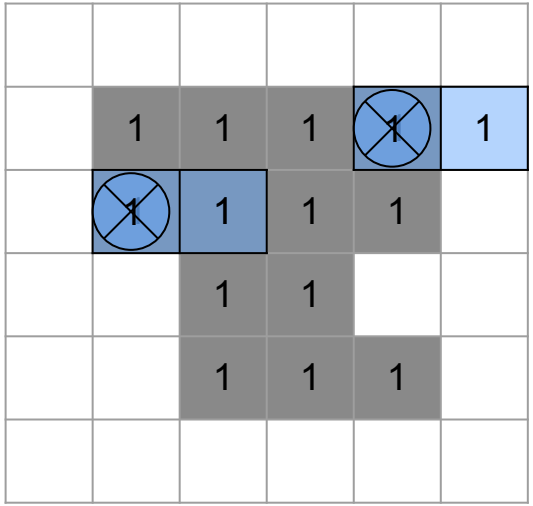

Imagem A

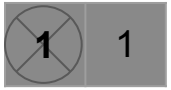

EE

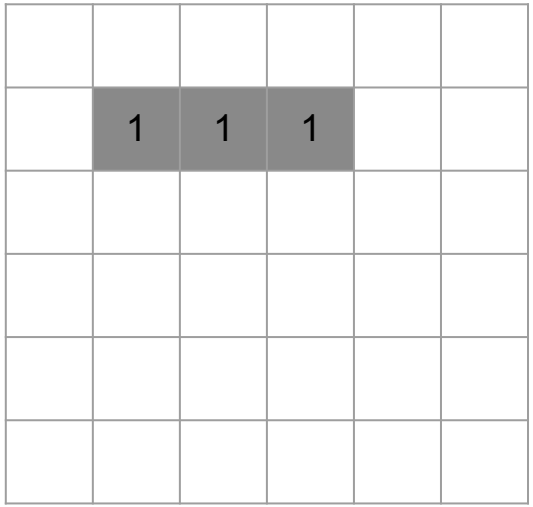

Resultado

Erosão

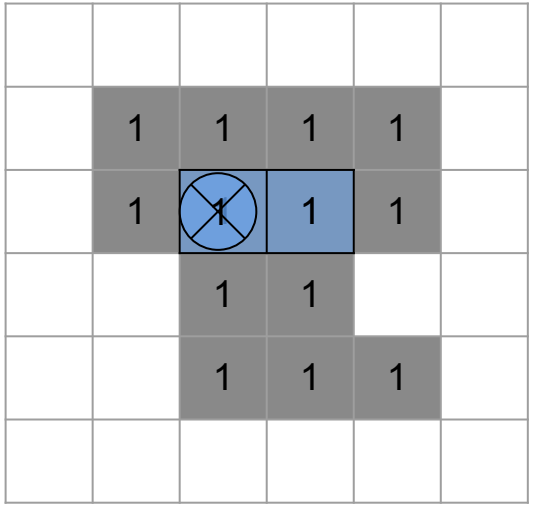

Imagem A

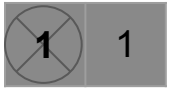

EE

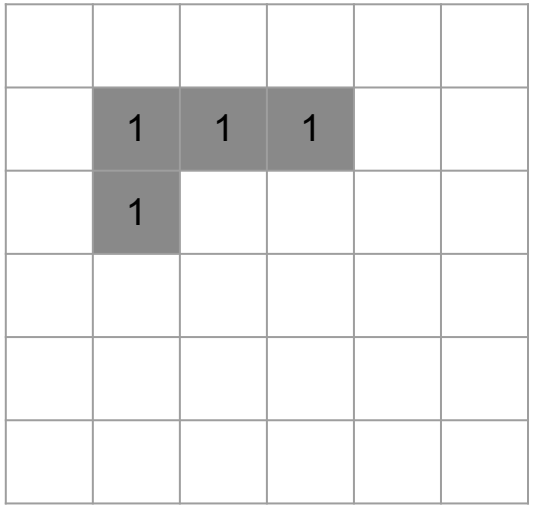

Resultado

Erosão

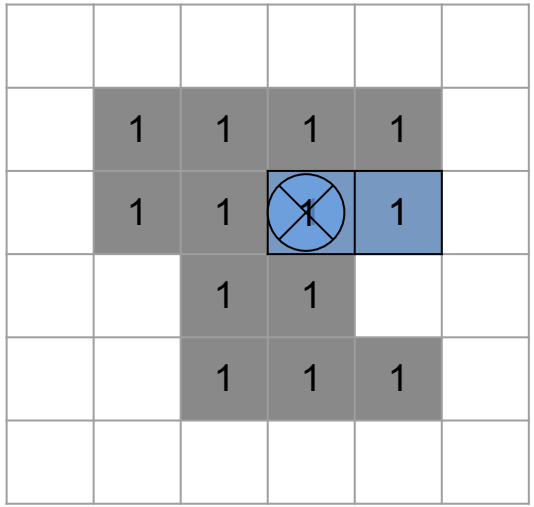

Imagem A

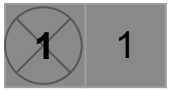

EE

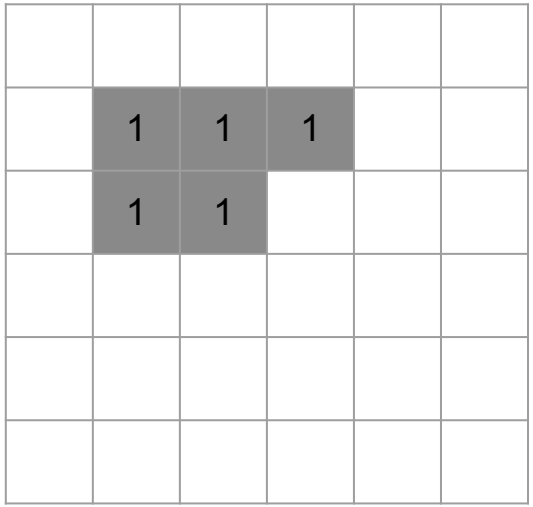

Resultado

Erosão

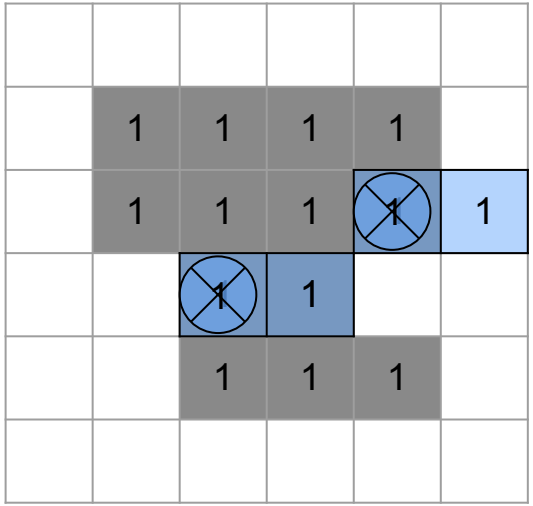

Imagem A

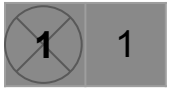

EE

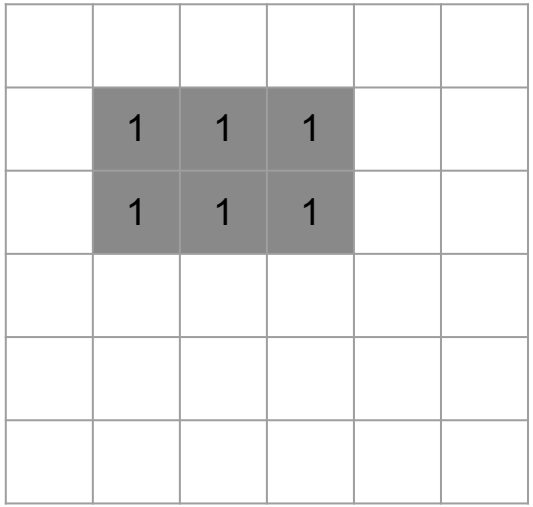

Resultado

Erosão

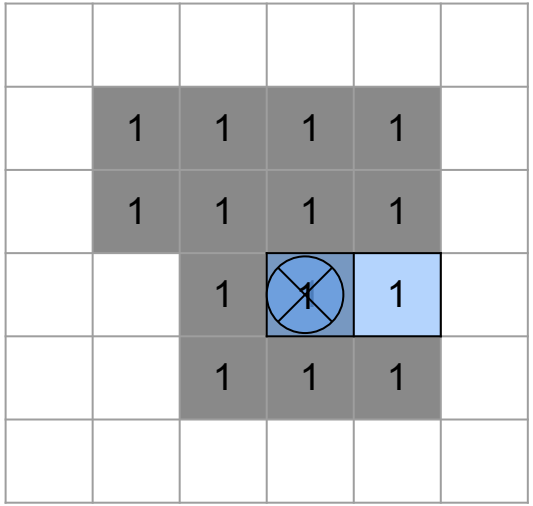

Imagem A

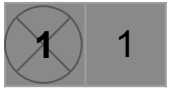

EE

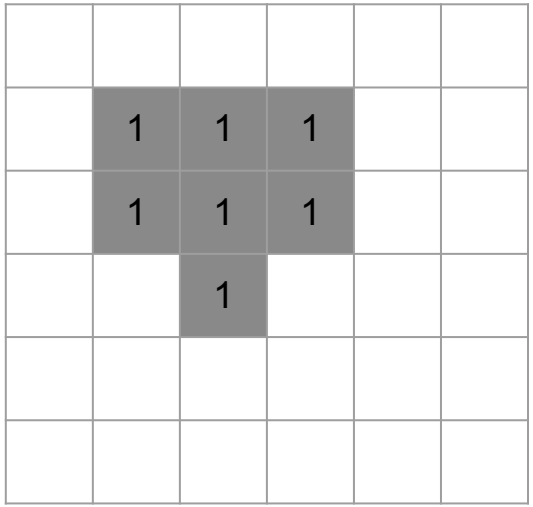

Resultado

Erosão

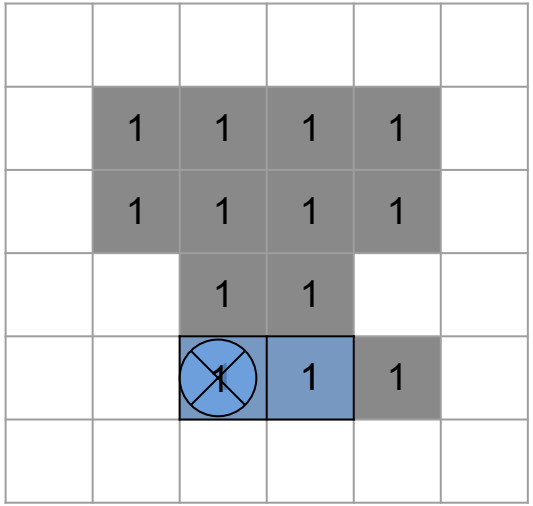

Imagem A

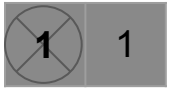

EE

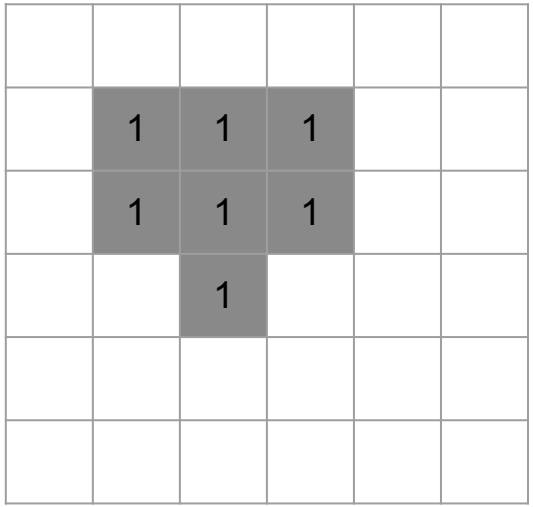

Resultado

Erosão

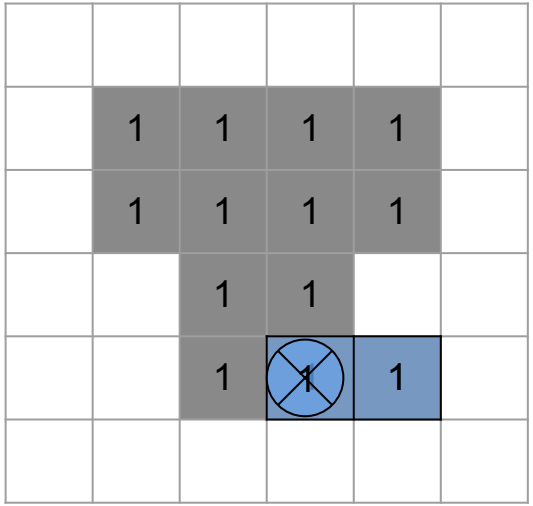

Imagem A

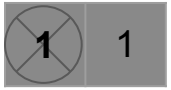

EE

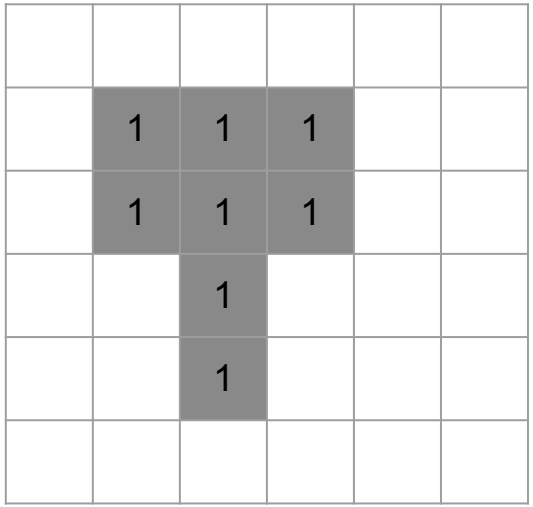

Resultado

Erosão

	1	1	1	1	
	1	1	1	1	
		1	1		
		1	1	1	

Imagem A

1	1

EE

	1	1	1		
	1	1	1		
		1			
		1	1		

Resultado

Erosão

Resultado: Diminuir conjuntos, remover pequenos objetos ou ruídos, mantendo a forma e o tamanho principal dos objetos maiores

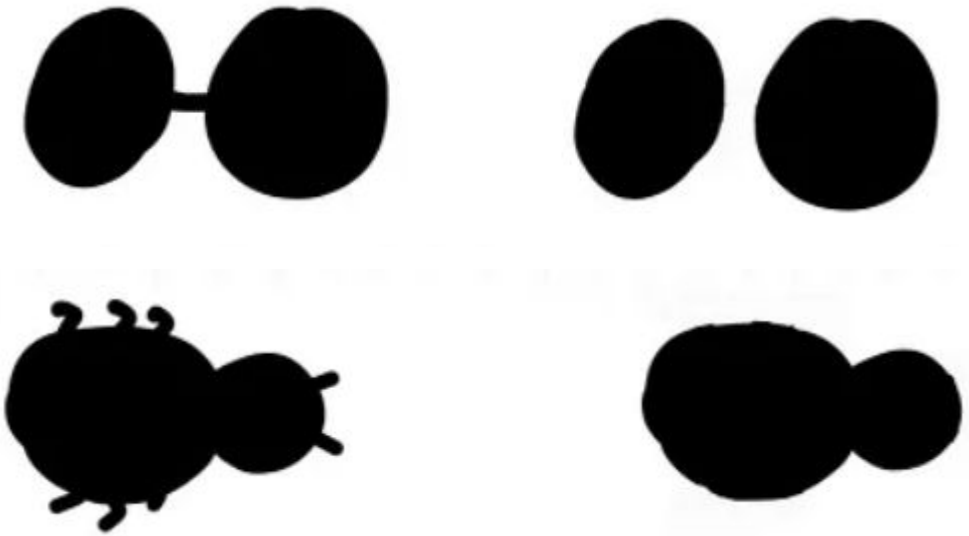

Fechamento

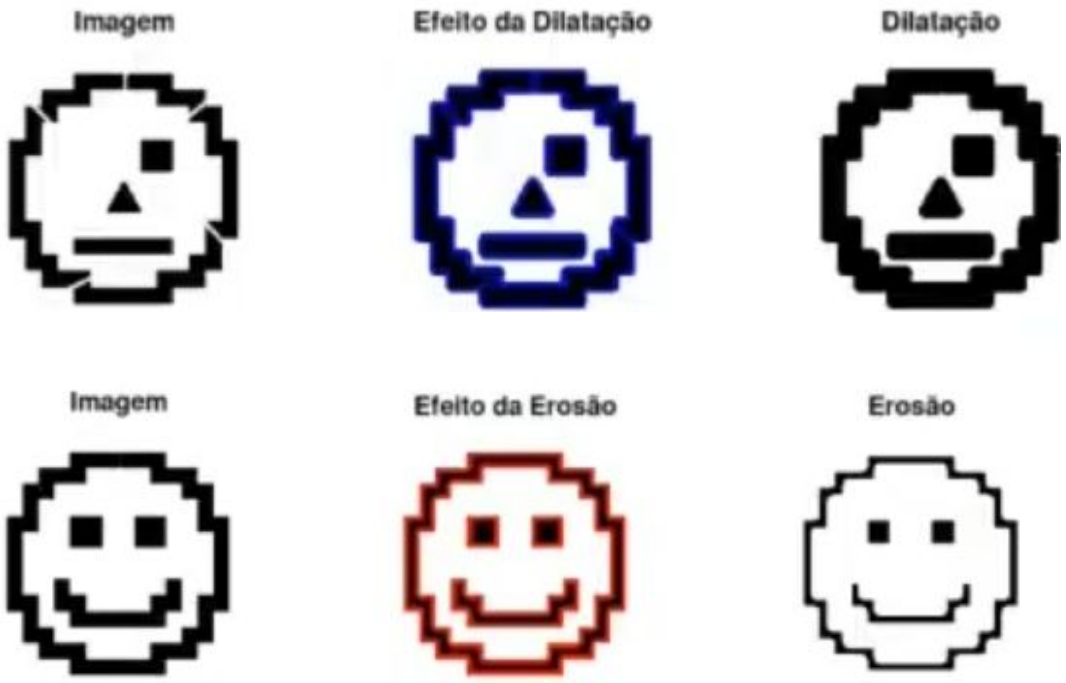
Imagem
Efeito da Dilatação
Dilatação
Imagem
Efeito da Erosão
Erosão

Erosão é o oposto de Dilatação?

	1		1		
	1	1	1		
		1			
		1	1		

Imagem pré dilatação

$\neq$

	1	1	1		
	1	1	1		
		1			
		1	1		

Resultado após erosão

Fechamento

Preenche pequenos buracos, liga objetos próximos e suaviza contornos

Condição: Realiza dilatação para unir áreas próximas e preencher falhas, depois erosão para restaurar a forma geral dos objetos

```
dilatacao(imagem)
erosão(imagem)
```

Fechamento

Resultado: Buracos são preenchidos e o formal original mais preservado

	1		1		
	1	1	1		
		1			
		1	1		

Imagem inicial

	1	1	1		
	1	1	1		
		1			
		1	1		

Imagem após fechamento

Fechamento

Abertura

Remove ruídos e objetos menores que o Elemento Estruturante, preservando a forma geral dos objetos maiores

Condição: Realiza erosão para remover pequenas partes e, em seguida, dilatação para restaurar a forma aproximada dos objetos preservados

```
erosão(imagem)
dilatacao(imagem)
```

Extra: Gradiente Morfológico

Um gradiente morfológico é a diferença entre dilatação e erosão

Resultado: Detecção de bordas dos objetos

Extra: Top-Hat (ou White-Hat)

É a diferença entre a imagem original e sua abertura.

Resultado: Realçar detalhes pequenos e claros sobre um fundo mais escuro

Extra: Black Hat

É a diferença entre o fechamento da imagem e a imagem original.

Exemplos práticos

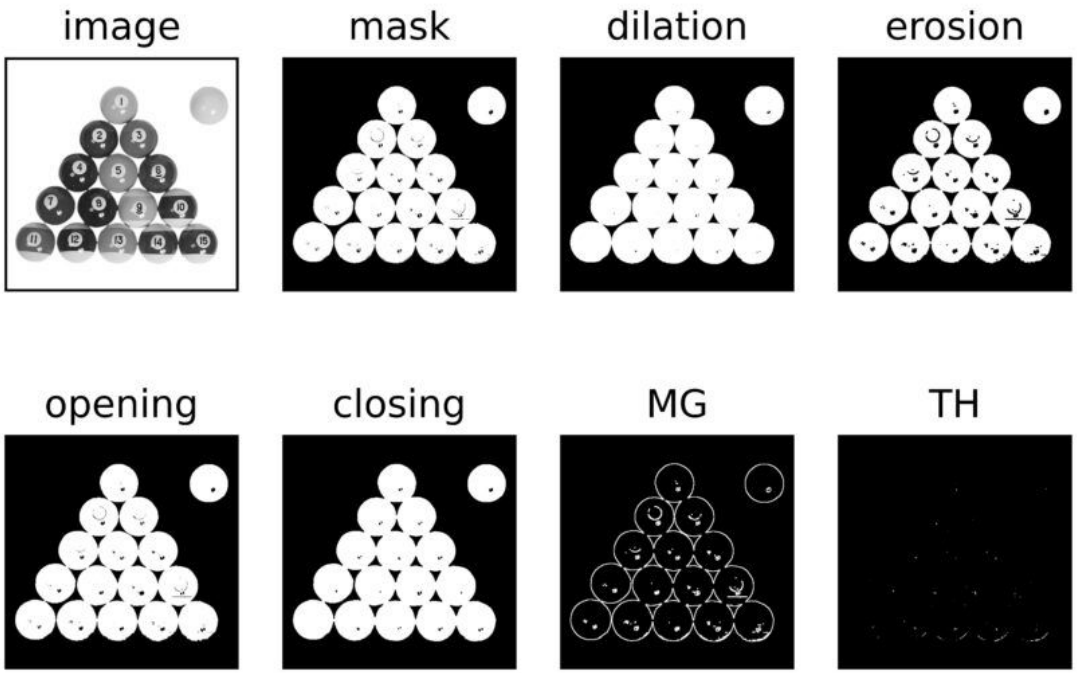

Exemplos práticos

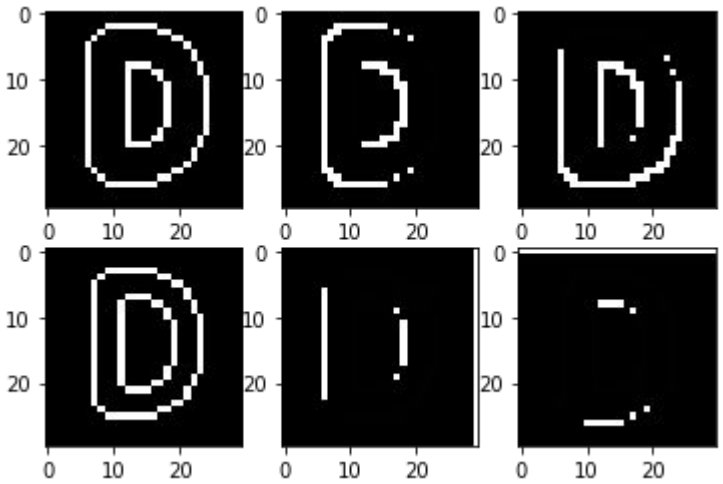

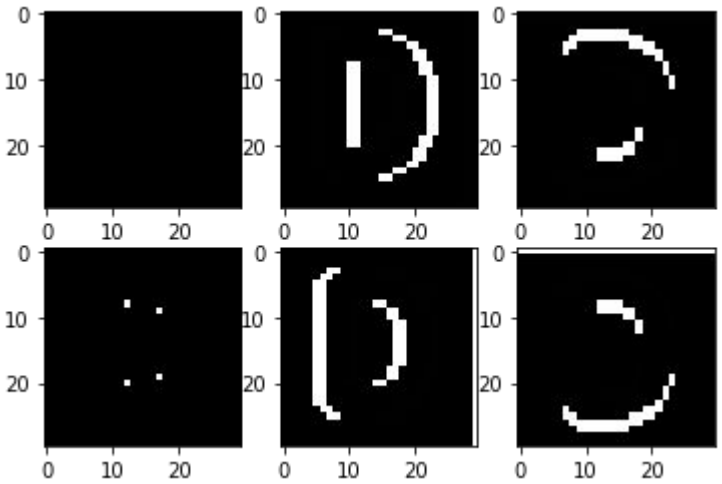

Exemplos práticos

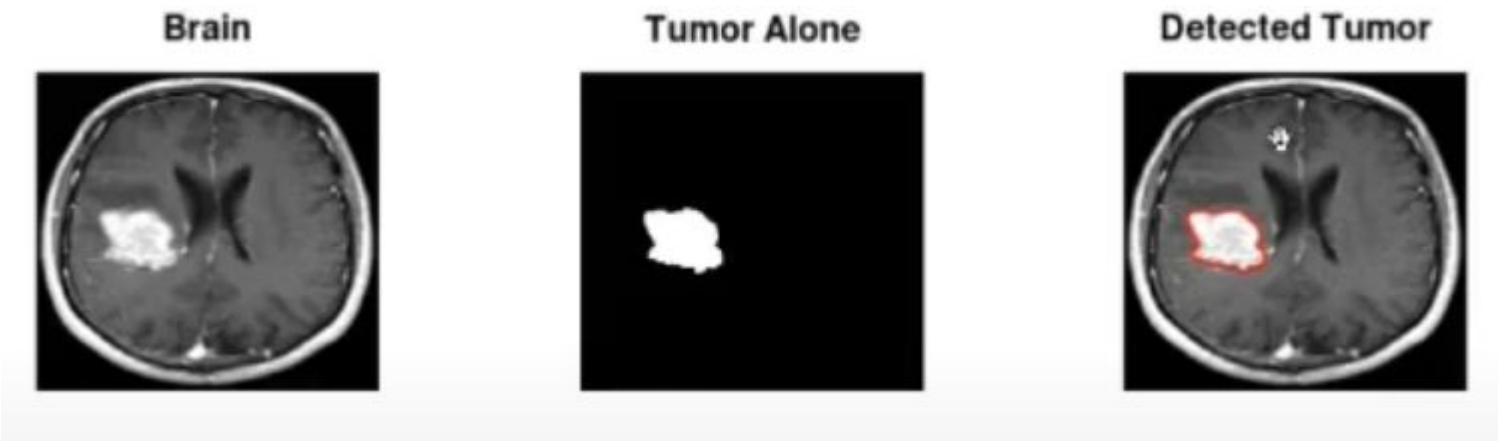

Sua vez de praticar

Historically, certain computer programs were written using only two digits rather than four to define the applicable year. Accordingly, the company's software may recognize a date using "00" as 1900 rather than the year 2000.

Precisamos aplicar **dilatação**

Sua vez de praticar

Historically, certain computer programs were written using only two digits rather than four to define the applicable year. Accordingly, the company's software may recognize a date using "00" as 1900 rather than the year 2000.

Historically, certain computer programs were written using only two digits rather than four to define the applicable year. Accordingly, the company's software may recognize a date using "00" as 1900 rather than the year 2000.

Sua vez de praticar

Sua vez de praticar

Técnicas de Segmentação

Técnicas Clássicas

São as abordagens tradicionais baseadas em propriedades locais ou globais da imagem, como intensidade, cor ou textura. Normalmente, elas exigem critérios bem definidos e operam de forma determinística

Técnicas Estocásticas

Usam modelos probabilísticos ou estatísticos para lidar com incertezas e variabilidades presentes nas imagens. Geralmente, trabalham melhor em cenários complexos ou com ruído.

Técnicas de Segmentação: Clássica

Principais métodos:

- **Thresholding (limiarização)** — segmenta a imagem com base em um valor de intensidade.
- **Detecção de Bordas** — identifica contornos a partir de gradientes ou diferenças de intensidade.
- **Crescimento de Regiões (Region Growing)** — expande regiões a partir de sementes com critérios de similaridade.
- **Divisão e Fusão de Regiões** — divide a imagem recursivamente e depois funde regiões semelhantes.

Vantagens: simples, rápida e fácil de implementar.
Limitações: sensível a ruído e variações de iluminação.

Técnicas de Segmentação: Estocásticas

Principais métodos:

- **Modelos de Mistura de Gaussianas (GMM)** — classifica pixels com base em distribuições probabilísticas
- **Modelos de Markov (MRF)** — consideram a relação espacial entre pixels
- **K-means (algoritmo de agrupamento)** — classifica pixels em clusters, minimizando a variância intra-cluster

Vantagens: mais robustas a ruídos e variações.
Limitações: maior custo computacional e necessidade de parametrização

Técnicas de Segmentação

Técnicas Híbridas (menção rápida)

Combinam técnicas clássicas e estocásticas ou integram métodos baseados em aprendizado de máquina e redes neurais. Muito comuns em aplicações modernas.

Exemplos:

- Segmentação inicial com thresholding + refinamento com MRF.
- Redes Neurais Convolucionais (CNN) para segmentação semântica ou de instâncias (ex.: U-Net, Mask R-CNN).

Vantagens: maior precisão e adaptabilidade.
Limitações: maior complexidade e demanda computacional.

Clássico: Thresholding

É uma técnica **simples e direta de segmentação de imagens** baseada na intensidade dos pixels.

A ideia central é definir um ou mais valores de **limiar (threshold)** e classificar os pixels conforme sua intensidade:

- **Acima do limiar** → pertence a uma classe (ex.: objeto)
- **Abaixo do limiar** → pertence a outra classe (ex.: fundo)

Clássico: Thresholding

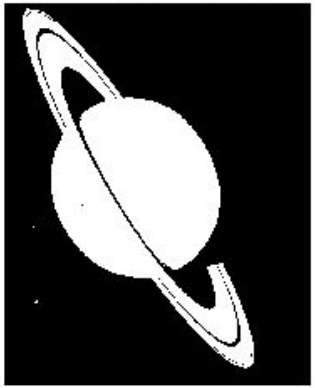

O resultado é uma imagem binária

Clássico: Thresholding

✅ **Vantagens**

- Simples de implementar
- Rápida (opera pixel a pixel)
- Boa para imagens com objetos bem contrastados

❌ **Limitações**

- Sensível a ruído e variação de iluminação
- Difícil de aplicar quando o histograma não apresenta picos bem definidos
- Pode falhar em imagens complexas ou de múltiplas classes

Clássico: Método de Otsu

Técnica automática para encontrar o valor de limiar ótimo para segmentação binária de imagens em tons de cinza.

O método testa todos os valores possíveis de limiar e calcula a **variância intra-classe** (variância dentro das regiões classificadas como fundo e como objeto), selecionando o limiar que resulta na menor variância intra-classe, ou equivalentemente, na maior separação entre os dois grupos.

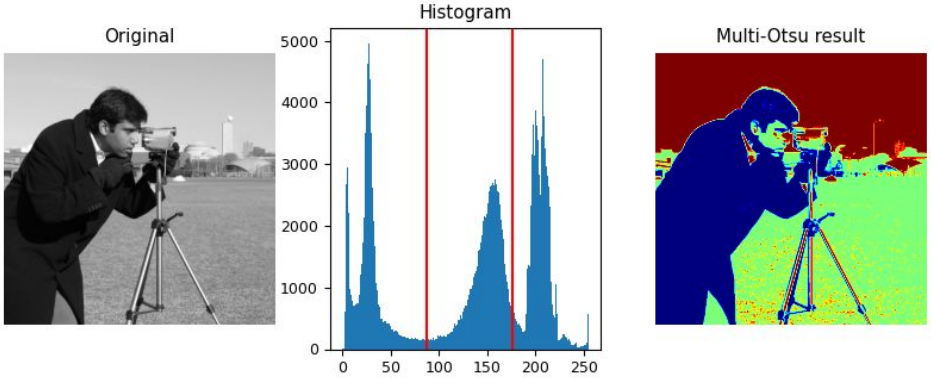

Clássico: Detecção de Bordas

As **técnicas baseadas em bordas** segmentam a imagem localizando as **descontinuidades nos níveis de intensidade** — ou seja, detectam onde há mudanças bruscas nos tons, que indicam os contornos dos objetos.

Operadores Clássicos

- **Sobel:** Calcula aproximações do gradiente nas direções horizontal e vertical. Simples e eficiente para detectar bordas grossas.
- **Canny:** Detector de bordas mais robusto.

1. Suavização com filtro Gaussiano
2. Cálculo do gradiente (intensidade e direção)
3. Supressão de não-máximos (afinamento da borda)
4. Histerese (duplo limiar) para conectar as bordas mais relevantes

Vantagens do Canny:

✔ Bordas finas
✔ Redução de ruído
✔ Melhor continuidade de contornos

Clássico: Detecção de Bordas

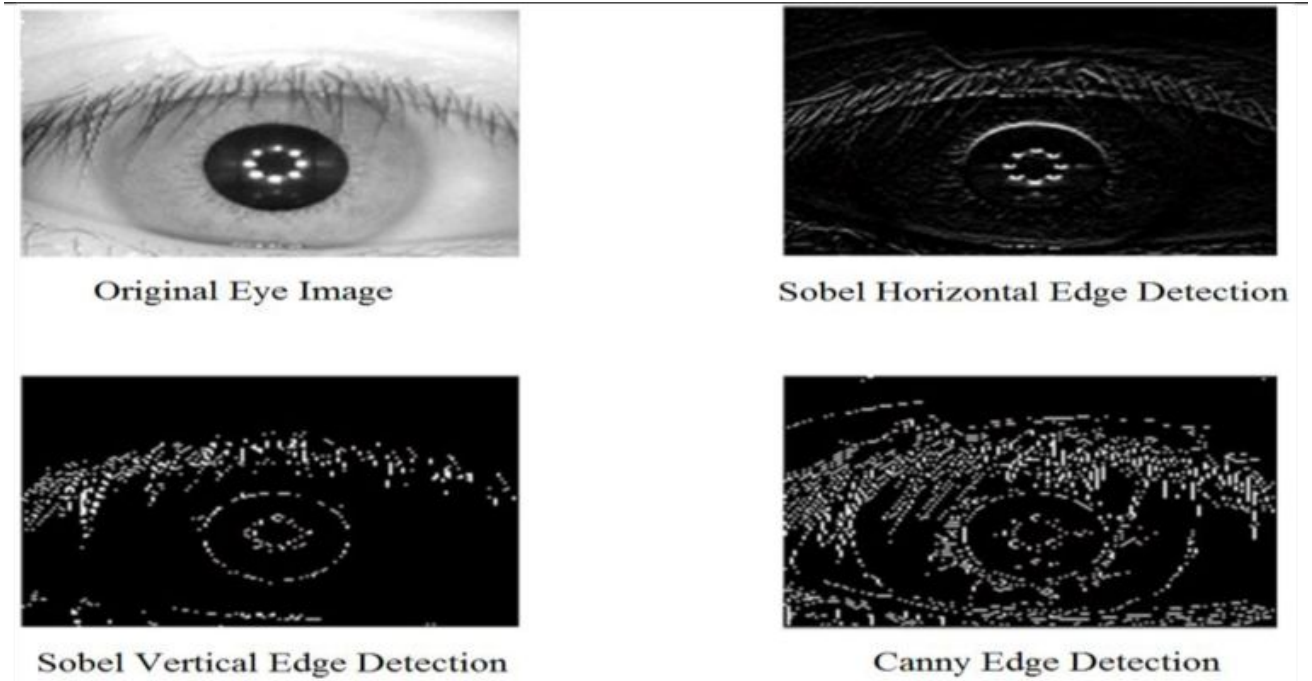

Valores altos do gradiente → possível borda

Clássico: Baseadas em Regiões

As **técnicas baseadas em regiões** segmentam a imagem agrupando pixels vizinhos que possuem **características semelhantes** (como intensidade, cor ou textura).

A ideia é formar regiões conectadas e homogêneas, respeitando algum critério de similaridade.

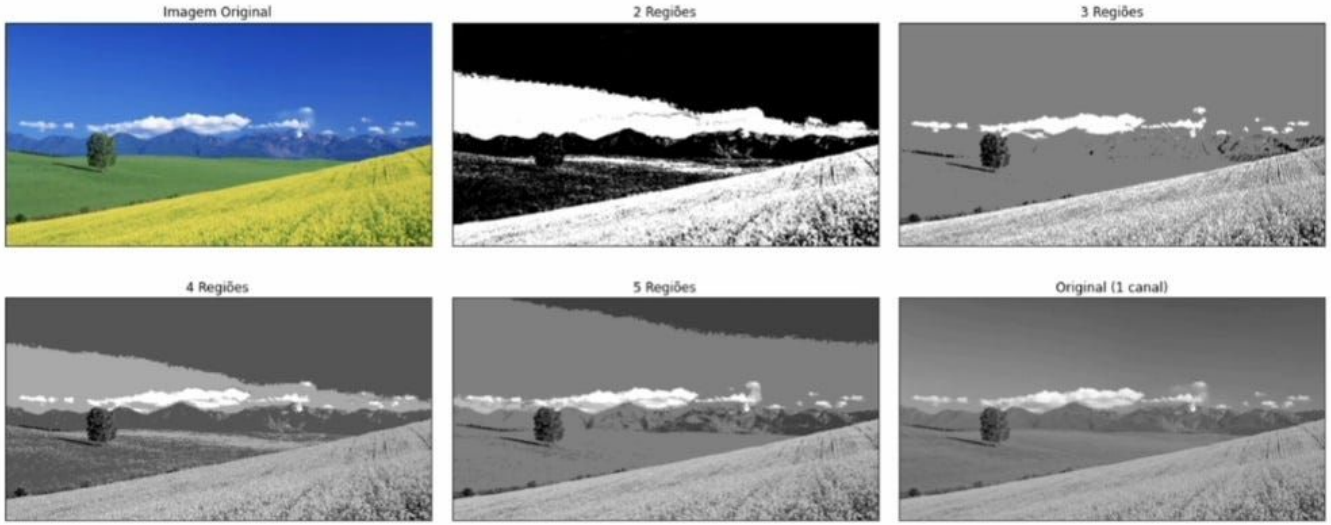

Clássico: Crescimento de Regiões

Como funciona:

1. Escolhe-se um ou mais **pontos-semente** a imagem.
2. Verifica-se os pixels vizinhos.
3. Adiciona-se à região os pixels que são semelhantes aos vizinhos já existentes (por exemplo: diferença de intensidade menor que um limite).

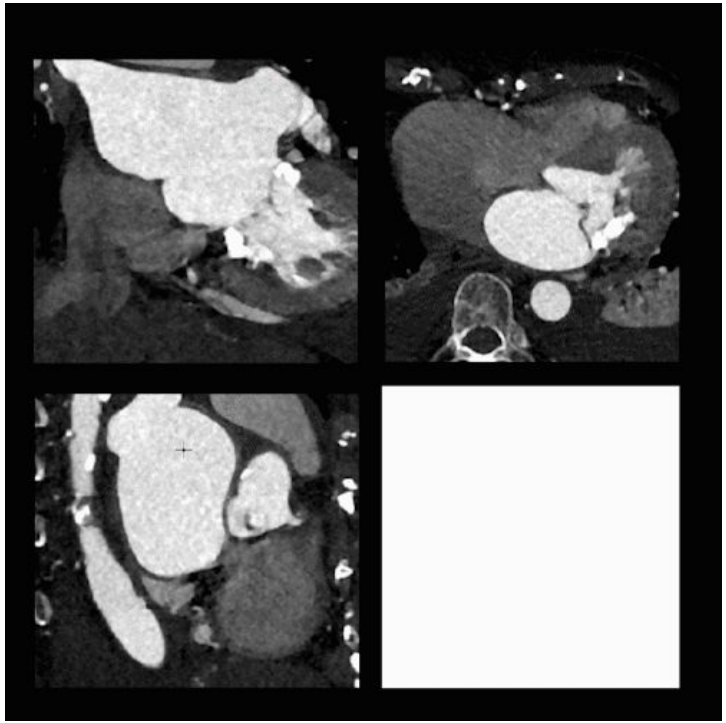

Critérios de parada:

- Quando não houver mais pixels vizinhos que satisfaçam a condição.
- Quando atingir um tamanho limite.

Clássico: Divisão e Fusão

Como funciona:

- **Divisão (Split):** divide recursivamente a imagem em blocos (normalmente quadrados) até que cada bloco satisfaça um critério de homogeneidade.
- **Fusão (Merge):** regiões adjacentes semelhantes são fundidas para formar regiões maiores.

Critério típico:
Diferença máxima de intensidade dentro do bloco menor que um limite.

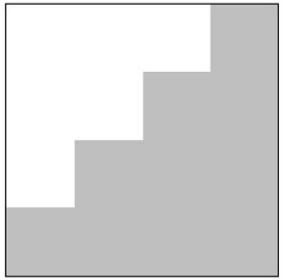

Figure. a

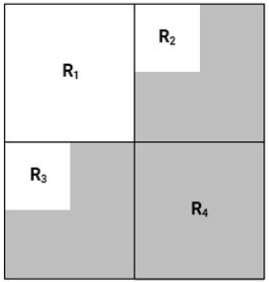

Figure. b

Figure. c

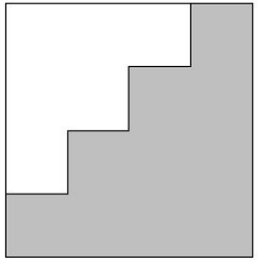

Figure. d

Técnicas de Segmentação clássicas

Técnica	Vantagens	Limitações	Sensibilidade a Ruídos	Dependência de Parâmetros
Thresholding	Simples, rápida, fácil de aplicar	Depende do contraste e histograma	Alta	Alta (valor de limiar)
Detecção de Bordas	Realça contornos, boa separação	Pode gerar bordas falsas ou falhas	Alta	Média (limiares, operador)
Region Growing	Boa em imagens homogêneas, define regiões conectadas	Sensível ao ponto-semente, lento	Média	Alta (seed, tolerância)
Split and Merge	Controla homogeneidade, detalhado	Alto custo computacional	Média	Alta (critério de fusão)

Técnicas de Segmentação clássicas (avançadas)

Além dos métodos já vistos, existem outros relevantes:

- **Watershed** → segmentação baseada em relevo/topografia.
- **Graph Cuts** → usa teoria dos grafos.
- **Textura** → filtros de Gabor, Haralick features.

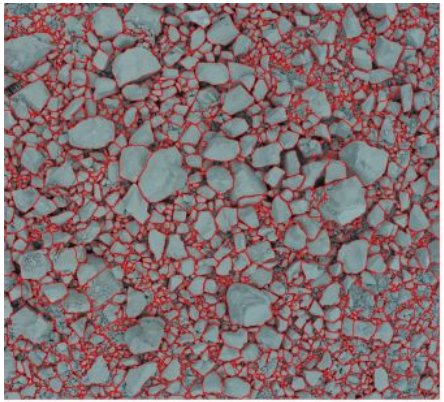

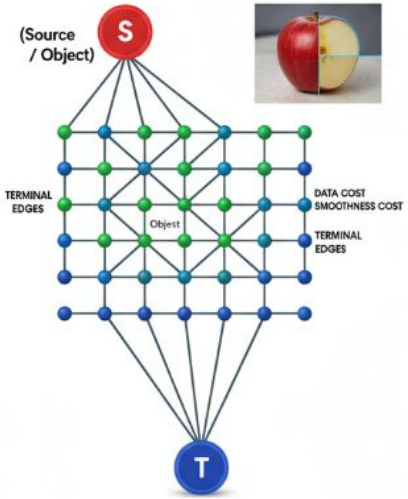

Técnicas de Segmentação Estocásticas

Como Funcionam

- Assumem que os pixels ou regiões pertencem a diferentes **classes estatísticas**.
- Estimam as **probabilidades** de cada pixel pertencer a cada classe.
- A segmentação é baseada na **máxima probabilidade** ou em critérios estatísticos de agrupamento.

Estocástica: K-Means

Algoritmo de agrupamento que particiona os pixels da imagem em **K grupos** baseados na similaridade (ex: intensidade, cor, textura). Classifica os pixels pela **distância ao centróide mais próximo**.

Processo iterativo:

1. Inicializa K centróides aleatórios.
2. Atribui cada pixel ao grupo mais próximo.
3. Atualiza os centróides com a média dos pixels do grupo.
4. Repete até os centróides estabilizarem.

Limitação: precisa definir **K** previamente.

Estocástica: Modelos de Markov (MRF)

MRF é um modelo probabilístico que representa uma coleção de variáveis aleatórias (por exemplo, pixels) com dependências locais. Cada pixel depende **apenas de seus vizinhos imediatos**, segundo a propriedade de Markov.

É usado para modelar relações espaciais e suavizar rótulos em imagens.

- A segmentação considera não só o valor individual do pixel, mas também a informação dos pixels vizinhos.
- Isso **reduz ruídos e inconsistências**, criando regiões mais homogêneas.
- Formalmente, o MRF define uma **função de energia** que penaliza rótulos diferentes em pixels vizinhos.

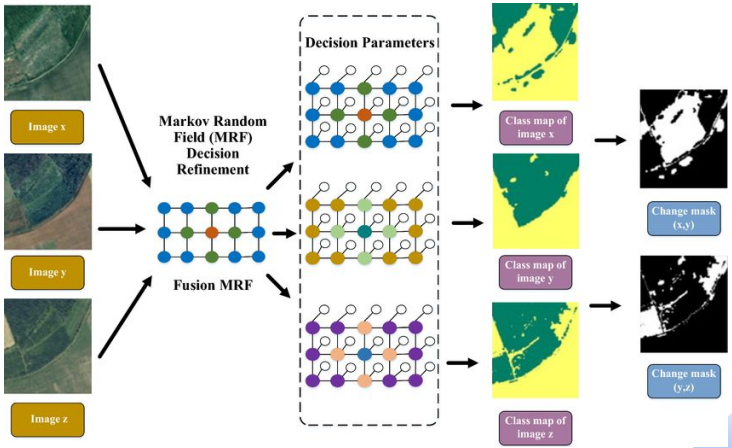

Estocástica: Modelos de Mistura de Gaussianas (GMM)

Um **modelo de mistura de gaussianas** assume que os dados (pixels da imagem) são gerados por uma combinação de várias distribuições gaussianas.

Cada gaussiana representa uma **classe** ou segmento diferente na imagem.O modelo representa a distribuição dos dados como a soma ponderada dessas gaussianas.

Exemplos de Aplicação

- Segmentação de imagens com múltiplas classes e distribuições complexas.
- Reconhecimento de padrões em imagens médicas (ex.: ressonância magnética).
- Separação de objetos em fundos heterogêneos.

Quando Usar Qual?

- **Técnicas Clássicas:**
  Quando a imagem é relativamente simples, com bom contraste entre objetos e fundo, e se busca uma solução rápida e direta.

- **Técnicas Estocásticas:**
  Quando a imagem tem ruído, texturas complexas, ou quando a segmentação precisa considerar dependências espaciais e incertezas, garantindo maior precisão e robustez.

Comparativo

Critério	Técnicas Clássicas	Técnicas Estocásticas
Simplicidade	Fáceis de implementar e computacionalmente rápidas.	Mais complexas, requerem modelagem estatística e métodos iterativos.
Robustez a ruído	Menos robustas; sensíveis a ruído e variações.	Mais robustas, incorporam modelos de ruído explícitos.
Flexibilidade	Limitadas a casos específicos, dependem da qualidade da imagem.	Adaptáveis a diversas condições, podem modelar dependências espaciais.
Interpretação	Intuitivas e diretas.	Menos intuitivas, interpretadas via probabilidades.
Qualidade do resultado	Pode gerar segmentações ruins em imagens complexas.	Geralmente melhor desempenho em imagens ruidosas ou complexas.
Requisitos computacionais	Menor custo computacional.	Alto custo computacional devido a otimizações e amostragem.

Técnicas mais avançadas

Métodos clássicos e estocásticos muitas vezes dependem de características feitas à mão ou suposições fortes sobre os dados

Escalam mal para grandes datasets e tarefas de segmentação "abertas" (sem conhecimento prévio sobre o que procurar)

Deep Learning na Segmentação

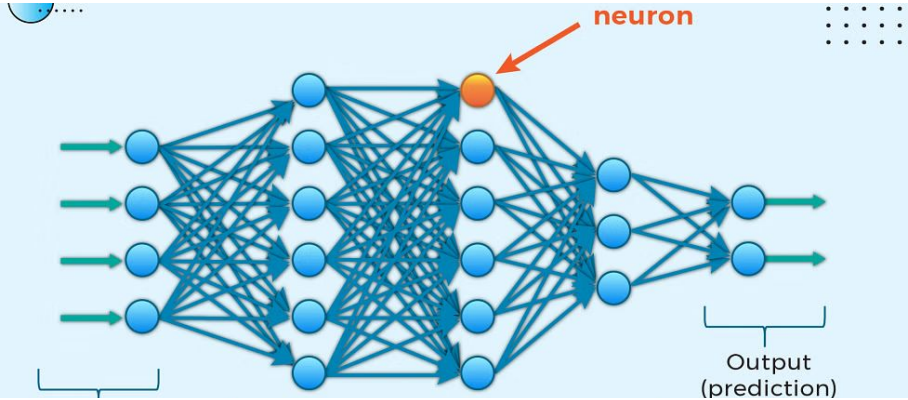

Deep Learning na Segmentação

Desempenho Superior: Capacidade de capturar padrões complexos e generalizar para novas situações de forma muito mais eficaz.

Segmentação Semântica:

- Classifica **cada pixel** da imagem em uma classe pré-definida (ex: céu, carro, pessoa)
- Trata todos os objetos da mesma classe como uma única entidade
  a. Todos os carros na imagem são rotulados como "carro", mas não se sabe "quantos" carros existem.

Segmentação de Instâncias:

- Identifica e segmenta **cada ocorrência individual de um objeto** em uma imagem.
- Combina detecção de objetos com segmentação.
  a. Cada carro na imagem é não apenas rotulado como "carro", mas também distinguido como "carro 1", "carro 2", etc., com uma máscara de segmentação para cada um.

Deep Learning na Segmentação

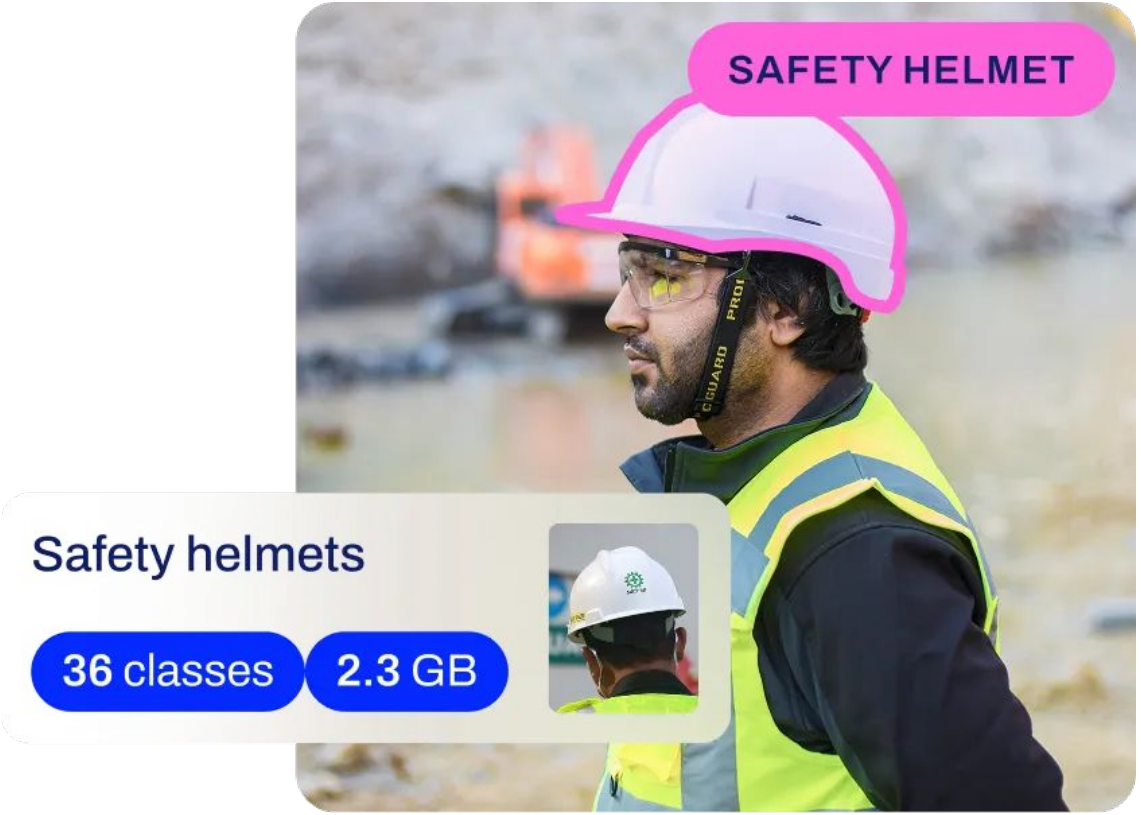

Qualidade da segmentação

Comparar resultados de diferentes modelos e otimizar o desempenho

Principais métricas:

- Pixel Accuracy (taxa de acerto pixel a pixel): A proporção de pixels que foram corretamente classificados (como parte do objeto ou do fundo) em relação ao total de pixels na imagem

- IoU (Intersection over Union) : Mede a sobreposição entre a área da segmentação prevista e a área da Ground Truth, dividida pela área da união dessas duas regiões.

- Dice Coefficient: Semelhante ao IoU, mas dá mais peso à área de interseção, sendo duas vezes a área de interseção dividida pela soma das áreas da Ground Truth e da segmentação prevista.

Qualidade da segmentação

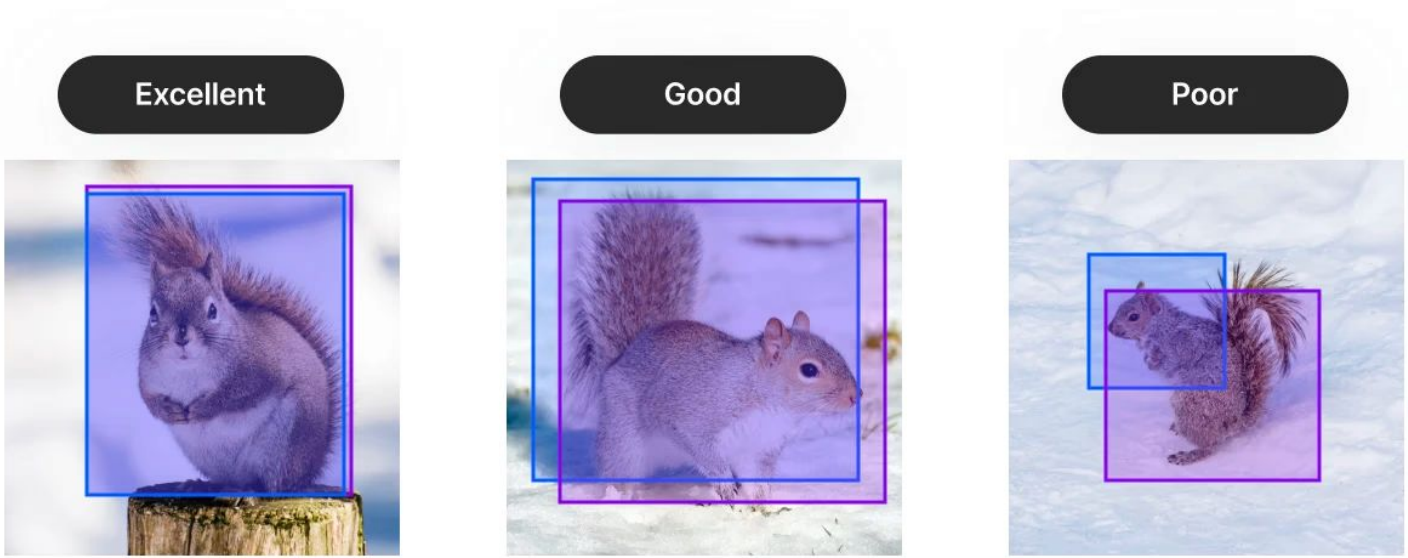

IoU= 0.95 IoU= 0.79 IoU= 0.45